

**SVEUČILIŠTE U SPLITU  
FAKULTET ELEKTROTEHNIKE, STROJARSTVA I  
BRODOGRADNJE**

**DIPLOMSKI RAD**

**PRIMJENA UMJETNIH NEURONSKIH  
MREŽA U KRATKOROČNOJ PROGNOZI  
RADA PROTOČNIH HIDROELEKTRANA**

**Tihomir Perković**

Split, rujan 2019.



Diplomski studij: Automatika i sustavi

Smjer/Usmjerenje: -

Oznaka programa: 210

Akadska godina: 2018./2019.

Ime i prezime: TIHOMIR PERKOVIĆ

Broj indeksa: 602-2017

## ZADATAK DIPLOMSKOG RADA

Naslov: PRIMJENA UMJETNIH NEURONSKIH MREŽA U KRATKOROČNOJ  
PROGNOZI RADA PROTOČNIH HIDROELEKTRANA

Zadatak: Proučiti literaturu o strukturi i funkcioniranju umjetnih neuronskih mreža, o režimima rada hidroelektrana. Posebnu pozornost obratiti na funkcioniranje malih i srednjih hidroelektrana koje imaju malu akumulaciju.  
Na osnovi dostupnih hidrometeoroloških podataka i mjerenja snage elektrane izraditi algoritam za procjenu kratkoročnog dotoka (do 48 sati) u akumulaciju hidroelektrane. Verificirati model na neovisnom setu podataka i dati komentar kvalitete postignutih rezultata.

Prijava rada: 04.03.2019.

Rok za predaju rada: 27.09.2019.

Rad predan:

Predsjednik  
Odbora za diplomski rad:

Mentor:

prof.dr.sc. Jadranka Marasović

izv.prof.dr.sc. Ozren Bego

## IZJAVA

Ovom izjavom potvrđujem da sam završni rad s naslovom PRIMJENA UMJETNIH NEURONSKIH MREŽA U KRATKOROČNOJ PROGNOZI RADA PROTOČNIH HIDROELEKTRANA pod mentorstvom izv. prof. dr. sc. OZREN BEGO pisao samostalno, primijenivši znanja i vještine stečene tijekom studiranja na Fakultetu elektrotehnike, strojarstva i brodogradnje, kao i metodologiju znanstveno-istraživačkog rada, te uz korištenje literature koja je navedena u radu. Spoznaje, stavove, zaključke, teorije i zakonitosti drugih autora koje sam izravno ili parafrazirajući naveo/la u završnom radu citirao sam i povezao s korištenim bibliografskim jedinicama.

Student

*Tihomir Perković*

Tihomir Perković

# SADRŽAJ

1.	UVOD .....	6
2.	HIDROELEKTRANE .....	7
2.1.	Općenito o hidroelektranama .....	7
2.2.	Male hidroelektrane, općenito .....	9
2.3.	Dijelovi male hidroelektrane .....	12
2.3.1.	Građevinski objekti .....	12
2.3.2.	Hidromehanička oprema.....	13
2.3.3.	Elektrostrojarska oprema.....	13
2.4.	Pomoćne usluge .....	17
2.5.	Kraljušćica 1 i 2 .....	18
3.	UMJETNA INTELIGENCIJA .....	21
3.1.	Podjela umjetne inteligencije .....	21
3.2.	Biološke neuronske mreže .....	22
3.3.	Umjetne neuronske mreže općenito .....	24
3.4.	Perceptron, Višeslojni perceptron, sigmoidni neuron.....	25
3.4.1.	Perceptron.....	25
3.4.2.	Sigmoidalni perceptron, ostale aktivacijske funkcije.....	27
3.4.3.	Višeslojni Perceptron .....	29
3.5.	Svojstva, mogućnosti i vrste umjetnih neuronskih mreža .....	31
3.5.1.	Vrste neuronskih mreža.....	33
4.	UMJETNE NEURONSKE MREŽE U HIDROLOGIJI.....	35
4.1.	Osnovni zadatci kod formiranja UNM-e u hidrologiji.....	35
4.2.	Hidrološki sustavi .....	35
4.3.	Algoritmi za treniranje .....	36
4.3.1.	Način rada algoritama .....	37
4.3.2.	Algoritmi korišteni u ovom radu.....	37
4.4.	Modeli vremenske serije .....	39
4.5.	Strukture UNM-e .....	39
4.6.	Ocjenjivanje modela .....	40
4.6.1.	Apsolutne mjere kvalitete modela.....	41
4.6.2.	Relativne mjere kvalitete .....	42
5.	TESTOVI, REZULTATI, ANALIZA .....	43
5.1.	Uvod.....	43
5.2.	Programski paket MATLAB .....	51
5.3.	Usporedba performansi Levenberg-Marquart i Bayesian algoritma .....	53
5.4.	Rezultati NARX strukture za LM algoritam .....	54
5.5.	Rezultati NAR strukture za LM algoritam .....	68
6.	ZAKLJUČAK.....	81
	LITERATURA.....	82
	POPIS KRATICA I OZNAKA.....	85
	SAŽETAK I KLJUČNE RIJEČI.....	87
	ABSTRACT AND KEYWORDS .....	88

### **Zahvala:**

*Hvala mojoj materi Tijani, ćaći Branimiru, sestri Anamariji, babi Andi, didu Anti, ujki Danijelu, na ogromnoj, svesrdno ukazanoj mi pomoći tijekom studiranja, također hvala strini Miri, stricu Mirki, ćaćinom mi stričeviću Tomislavu te ostatku obitelji i prijateljima na ukazanoj mi podršci bilo koje vrste.*

*Posebna hvala mojim mentorima, prof. dr. sc. Ozrenu Begi i prof. dr. sc. Petru Matiću na savjetima i pomoći oko izrade ovog diplomskog rada, te svima ostalima koji su pridonijeli ovome radu prikupljanjem i obradom podataka.*

*Završivši elektrotehnički fakultet koji je prepun matematike i fizike, koje mi tijekom ranijih faza obrazovanja i nisu baš išle, dokazah da znam koristiti mozak i meni dosta. Sada se mogu vratiti u Livno, čuvati ovce i lagano mozak pustiti na pašu skupa s ovcama.*

*#LiveLongAndProsper \\\_///*

# 1. UVOD

Umjetne neuronske mreže posljednjih godina dobivaju zamah u mnogim djelatnostima, teško je pronaći neku djelatnost koja se ne može unaprijediti primjenom umjetne inteligencije. Pa tako i djelatnost proizvodnje i distribucije električne energije. No, umjetne neuronske mreže nisu „čarobni štapić“ pomoću kojega možemo lako otkloniti svaki problem koji poželimo. Efikasnost umjetnih neuronskih mreža ovisi o vrsti problema, postavljenim zahtjevima, varijablama, parametrima, uvjetima...

Ovaj diplomski rad se bavi mogućnošću primjene umjetne neuronske mreže u procesu proizvodnje električne energije. Konkretno, istraživanjem mogućnosti modeliranja umjetne neuronske mreže koja će na temelju vremenskih prognoza za oborine i podataka o snazi elektrane, predviđati potrebe za količinom proizvedene električne energije dvadeset i četiri sata unaprijed. Model umjetne neuronske mreže se odnosi na malu hidroelektranu „Kraljušćica“ u Konjicu (BiH). Motiv za pokušaj izrade umjetne neuronske mreže sa navedenom funkcijom leži u samoj tehničkoj izvedbi malih hidroelektrana. Zbog specifične tehničke izvedbe, koja će detaljnije biti opisana u nastavku ovoga rada, postoji potreba za preciznim predviđanjem potreba i mogućnosti proizvodnje električne energije. Naime, takve elektrane su izrazito osjetljive na promjenu dostupnosti ulaznog vodenog toka a vodeni tok uvelike ovisi o meteorološkim uvjetima u okolišu, između ostalih, i o oborinama.

## **2. HIDROELEKTRANE**

### **2.1. Općenito o hidroelektranama**

Hidroelektranu u širem smislu čine sve građevine i postrojenja, koje služe za prikupljanje (akumuliranje), dovođenje i odvođenje vode (brana, zahvati, dovodni i odvodni kanali, cjevovodi itd.), pretvorbu energije (vodne turbine, generatori), transformaciju i razvod električne energije (rasklopna postrojenja, dalekovodi) te za smještaj i upravljanje cijelim sustavom (strojarnica i sl.) kao i svi prateći sustavi koji osiguravaju siguran i pouzdan rad HE [1].

Ovisno o izvedbi hidroelektrane, za proizvodnju električne energije može se iskoristiti potencijalna ili kinetička energija vode. Gradnjom brana i formiranjem akumulacijskih jezera koristi se potencijalna energija vode, dok se kinetička energija vode pretvara u električnu iskorištavanjem toka rijeke, morskih mijena, energije valova. Načini pretvaranja energije vode u električnu energiju su mnogobrojni no svaki od tih načina ima isti osnovni princip funkcioniranja.

Osnovni princip funkcioniranja svodi se na pokretanje turbine energijom vode gdje u daljnjem procesu turbina pokreće generator električne energije a zatim se dobivena električna energija distribuira u elektroenergetsku mrežu [2].


Prema tipovima hidroelektrane mogu biti protočne (bez ili s malom satnom/dnevnom akumulacijom) ili akumulacijske (s akumulacijom, branom, vodenom komorom, zahvatom, gravitacijskim dovodom, zasunskom komorom, tlačnim cjevovodom, strojarnicom i sustavom odvodnje vode) [2].

Prema načinu proizvodnje razlikuju se:

- Pribranske, kod kojih je strojarnica uz ili u brani.
- Derivacijske, kod kojih je strojarnica izmještena dalje od brane.
- Reverzibilne, koje su akumulacijske HE s dvije akumulacije (gornja i donja). Proizvode energiju klasično padom vode iz gornje akumulacije, ali mogu raditi i kao crpke koje crpe vodu iz donje akumulacije u gornju kako bi se ta voda mogla ponovno energetski iskorištavati. Za crpljenje se koristi električna energija iz elektroenergetskog sustava u vrijeme kada ima viška energije (npr. noću).

- Crpne, hidroenergetska postrojenja kojima je osnovni zadatak crpljenje (sakupljanje) vode u višim akumulacijama za potrebe neke klasične HE (u čijem su tehnološkom sastavu), a kada se voda iz akumulacije koristi u osnovnoj HE, rade kao klasična HE te i one koriste energiju iste vode povećavajući ukupni stupanj iskoristivosti [2].

Proizvodnja električne energije u hidroelektranama je najefikasniji način proizvodnje električne energije. Efikasnost ovisi o izvedbi hidroelektrane odnosno o izvedbi turbine. Efikasnost hidroelektrana premašuje vrijednost od 80%. Efikasnost je vrlo visoka zbog malih ili nepostojećih gubitaka uzrokovanih termodinamičkim i kemijskim procesima. Određeni mehanički i drugi gubici uvijek postoje pa efikasnost nikada ne može doseći vrijednost od 100%. Usporedba efikasnosti različitih elektrana može se vidjeti na *Slici 1*:



*Slika 2.1. Efikasnost različitih vrsta hidroelektrana [3]*

Podjela hidroelektrana prema maksimalnoj mogućoj proizvodnji snage:



*Tablica 2.1. Klasifikacija elektrana prema snazi u SAD-u [4]*

Vrsta hidroelektrane	Snaga
Mikro	1 kW – 100 kW
Mini	100 kW – 1 MW
Mala	1 MW – 30 MW
Velika	30+ MW

Ponekad se hidroelektrane srednje veličine definiraju kao elektrane snage 5 MW - 50 MW.

U ovom radu naglasak je stavljen na male i srednje hidroelektrane, dakle, hidroelektrane snage 1 MW – 50 MW [4].

## **2.2. Male hidroelektrane, općenito**

Izbor tipa hidroelektrane ovisi u prvom redu o morfologiji prostora, urbanističkim zahtjevima, ekološkim zahtjevima i dr. Jedna od najvećih prednosti malih hidroelektrana je u nezahtjevnoj infrastrukturi, vrlo lako ih je izgraditi i održavati te se lako mogu spojiti s lokalnom električnom mrežom.

Ovaj rad će se baviti dvjema hidroelektranama na vodotoku rijeke Kraljušćice, općina Konjic, Bosna i Hercegovina. Hidroelektrana „Kraljušćica 1“ instalirane snage 3.465 kW i predviđene godišnje proizvodnje 12.500 MWh te hidroelektrana „Kraljušćica 2“ instalirane snage 4.478 kW i predviđene godišnje proizvodnje 18.950 MWh [5].


Derivacijske male hidroelektrane, poput ovih na rijeci Kraljušćici, preusmjeravaju tok rijeke kroz posebno izgrađene kanale ili cijevi prema turbinama gdje onda započinje proces proizvodnje električne energije. Tok vode se preusmjerava na višoj nadmorskoj visini, turbine se nalaze na nižoj nadmorskoj visini. Prirodan pad, odnosno gravitacijska sila predaje kinetičku energiju koja se poslije pretvara u električnu. Nakon toga voda se ponovno vraća u riječno korito. Jednostavna ilustracija na *Slici 2* prikazuje kako taj sustav funkcionira.



*Slika 2.2. Jednostavni shematski prikaz male derivacijske hidroelektrane*

Nije dopušteno prema hidroelektrani preusmjeravati sto posto toka rijeke nego se određena količina vode pušta svojim uobičajnim tokom kroz riječno korito a sve u svrhu zaštite riječnog života. Taj tok se naziva ekološkim minimumom i za svaku rijeku se posebno računa. Osim toga, grade se posebni kanali u svrhu neometanog kretanja riba.

Turbine u hidroelektranama se konstruiraju za određen raspon toka. U tome rasponu turbine rade optimalno ili približno optimalno. Izvan barem približno optimalnog toka, bio on premalen ili prevelik, rad turbine nije na zadovoljavajućoj razini. Rijeke ovoga tipa su osjetljive na sezonske pa čak i dnevne fluktuacije toka vode pa se zbog toga ponekad grade male akumulacije vode pomoću kojih se održava optimalan rad turbina u sušnim razdobljima. U poplavnim razdobljima, tj. razdobljima prevelikog dotoka, višak vode se propušta i ta energija se ne iskorištava. Zbog problema koje može uzrokovati nestabilan dotok vode, male hidroelektrane trebaju imati neki od rezervnih oblika napajanja električnom energijom, kao što su baterije, generatori za izvanredne situacije, priključak na lokalnu mrežu [6].



Slika 2.3. Shematski prikaz strojnice male hidroelektrane [6]

Glavne komponente male hidroelektrane su sljedeće strukture i uređaji:

- Građevinski objekti
- Hidromehanička oprema
- Elektrostrojarska oprema
- Priključak na dalekovodnu mrežu

Prema geodetskom padu se dijele na hidroelektrane koje mogu imati:

- Visoki pad: 100 m i više
- Srednji pad: 30 m - 100 m
- Niski pad: 2 m - 30 m

A na osnovu konfiguracije mikrolokacije i samog vodotoka dijele se na:

- Protočne elektrane (*eng. Run-off-river schemes*)
- Postrojenja sa strojarnicom u podnožju brane
- Postrojenja integrirana u kanal za navodnjavanje
- Postrojenja integrirana u sklopu vodozahvata

Prema poziciji strojnice u odnosu na branu, koja može biti smještena uz branu/zahvat vode ili dalje od brane, hidroelektrane se dijele na:

- Pribranske
- Derivacijske s otvorenim kanalom

- Derivacijske sa zatvorenim kanalom
- S tlačnim cjevovodom [2], [6].

## **2.3. Dijelovi male hidroelektrane**

### **2.3.1. Građevinski objekti**

#### **Brana:**

Općenito, branom, ili u ovom slučaju bolje reći niskim preljevnim pragom, omogućuje se nesmetan zahvat vode koji se dalje odvodi prema hidroelektrani [7].

#### **Ulazni uređaj (zahvat):**

Zahvatom se, kao što i sam naziv implicira, zahvaća voda koja se dalje usmjerava prema hidroelektrani. Dva su tipa zahvata, bočni zahvat i tirolski zahvat.

Kod bočnog zahvata, bočnim ulaznim uređajem branom usporena voda zahvaća se bočno. Uz pomoć rešetki za filtriranje sprječava se ulaženje nanosa i plutajućih objekata u kanal [7].

Kod vodozahvata u dnu (tzv. tirolskog zahvata) voda se upušta u sabirni kanal kroz horizontalnu ili nagnutu rešetku. Pomoću tirolskog zahvata mogu se iskoristiti vrlo mali protoci vode te funkcionira bez ljudskog prisustva tijekom eksploatacije. Pogodan je za brdske, nepristupačne lokacije [7], [8].

#### **Dovodni kanal:**

Dovodi vodu, sa što manje gubitaka na padu, do ulaza na turbinu, tlačnog cjevovoda ili strojarnice [7].

#### **Strojarnica:**

Kod malih hidroelektrana strojarnice su skoro potpuno automatizirane jedinice u kojima se odvija samo povremeni nadzor. Ugradnjom turbine sa integriranim generatorom te su dimenzije zahvata i opreme znatno manje pa su shodno tome i dimenzije strojarnice znatno smanjene [7].

### **Odvodni kanal:**

Odvodnim kanalom voda se vraća natrag u korito rijeke. Taj kanal je najčešće kratak zato jer se strojarnica najčešće nalazi vrlo blizu korita rijeke. U većini slučajeva strojarnica male hidroelektrane smještena je uz sam vodotok. Tada je odvodni kanal vrlo kratak, betoniran, pravokutnog poprečnog presjeka, u usponu 1/4 prema koritu vodotoka, a bokovi mu se šire pod malim kutom [7].

### **2.3.2. Hidromehanička oprema**

Pomični elementi na brani su različiti segmentni zatvarači, preljevne zaklopke, gredne zapornice na branama, gumene nadbrane ispunjene zrakom ili vodom pod malim pretlakom... Njihova svrha je kontrola gornjih slojeva toka vode [7].

Elementi vodozahvata:

- Zapornice: koriste se za povremeno ispuštanje vode.
- Grube rešetke: služe za filtriranje vode od onečišćenja većih dimenzija.
- Fine rešetke: služe za filtriranje vode od onečišćenja manjih dimenzija.
- Grube i fine rešetke služe za zaustavljanje većih mehaničkih onečišćenja rijeke (stabla, veliko kamenje i sl.). Čiste se povremeno mehaničkim putem.
- Fine rešetke zaustavljaju manje nečistoće rijeke poput boca, plastičnih vrećica, manjeg kamenja i sl.
- Zbog manjeg otvora ovih rešetki češća su začepljenja, pa su time povećani i hidraulički gubici. Zbog toga se čiste automatiziranim strojevima za čišćenje. Zbog jake korozije kojoj su izložene, u novije se vrijeme pocinčavaju [7].


### **2.3.3. Elektrostrojarska oprema**

#### **Turbina:**

Turbina transformira kintetičku energiju vode u mehaničku energiju rotirajućih dijelova turbine. Izbor tipa turbine ovisi o tipu i karakteristikama hidroelektrane. Turbine mogu imati efikasnost do oko 90%. Osnovna podjela turbina je na reakcijske i akcijske turbine [7].

### Reakcijske turbine:


Potpuno su uronjene u vodu, pad tlaka na lopaticama turbine proizvodi njenu obodnu snagu, *Slika 2.4.* . Obodna brzina se pretvara u snagu osovine, neki od tipova reakcijskih turbine su: Propelerna, Francisova i Kaplanova turbina [7].



*Slika 2.4. Način pokretanja reakcijskih turbine [7]*

### Akcijske turbine (impulsne):

Zovu se još i turbine slobodnog mlaza, imaju udubljene lopatice i okreću se u zraku, *Slika 2.5.* . Koriste se kod velikih tlakova, odnosno velikih padova ( $>10$  m). Koriste se najčešće u uvjetima plitkih, brzih vodenih tokova. Neki od tipova akcijskih turbine su: Peltonova, Turgo te Banki-Michell/crossflow [9].



*Slika 2.5. Način pokretanja akcijskih turbine [7]*

### Pelton turbina:

Pelton akcijska turbina idealna je za hidroelektrane niskih snaga do 10 kW, no moguća je primjena i kod velikih hidroelektrana do 100 MW. Efikasnost ove turbine je do 95% [7].

Hidroelektrane “Kraljušćica I” i “Kraljušćica II” koriste upravo ovu turbinu. Prikazana je na *Slici 2.6.* .



*Slika 2.6. Pelton turbina [10]*


**Multiplikatori:**

Koriste se u malim hidroelektranama kod geodetskih padova manjih od 20 metara kako bi povećali broj okretaja turbine na odgovarajući broj okretaja generatora [7].

**Generatori:**

Pretvaraju mehaničku energiju u električnu. Uglavnom se sastoje od nepokretnog statora unutar kojeg se nalazi pokretni rotor koji se okreće vanjskim pogonskim strojem. Mogu proizvoditi istosmjernu ili izmjeničnu električnu struju, *Slika 2.7.* .

Izmjenični generatori se dijele na sinkrone i asinkrone te također na jednofazne i višefazne izmjenične generatore [11].



Slika 2.7. Shema generatora sa turbinom [6]

Sinkroni generatori mogu funkcionirati izolirano, odvojeni od elektroenergetske mreže, opremljeni su rotacijskim ili statičnim pobudnim sustavom koji može biti DC izvedbe ili izvedbe s permanentnim magnetom, povezani sa regulatorom napona u svrhu kontrole napona prije spajanja na mrežu. Koriste se u manjim, izoliranim mrežama, za samostalne primjene kod malih hidroelektrana, također kao primarni izvori proizvodnje energije u elektroenergetskim sustavima [7].

Asinkroni generatori uzбудnu struju vuku iz mreže na koju su spojeni, što znači da ne mogu raditi van mreže jer sami nisu u stanju proizvesti uzбудnu struju. Koriste se u situacijama kada kvaliteta električne energije nije od presudne važnosti [7], [9].

#### **Transformatori:**

Koristi se kod postrojenja većih snaga, iznad 100 kW jer se u tim slučajevima predviđa se priključivanje HE na mrežu višeg napona. Ukoliko su snage manje, postrojenje se priključuje direktno na distribucijsku mrežu nižeg napona [7].



## 2.4. Pomoćne usluge

*”Pomoćne usluge su dobavljive pojedinačne usluge, koje daje korisnik mreže (npr. proizvođač) ili operator distribucijskog sustava (ODS) na zahtjev operatora prijenosnog sustava (OPS) i za čiju dobavu (tehničko rješenje, pogonski troškovi) OPS računa s primjerenom naknadom troškova. Te usluge koristi operator prijenosne mreže za ostvarenje usluga sustava. Vjetroelektrane s asinkronim pogonom su osobit tip proizvodnih jedinica na koje se u pravilu ne primjenjuju odredbe ovim mrežnih pravila u pogledu pružanja pomoćnih usluga” [13].*

Na temelju posebnih ugovora, operator se obvezuje na dobavljanje pomoćnih usluga korisnicima mreže a glavne pomoćne usluge su: održavanje frekvencije, održavanje napona, rotirajuća pričuva, hladna pričuva, ponovna uspostava napajanja (crni start), vozni red [14].

### **Usluga regulacije frekvencije:**

Kada u sustavu nastane poremećaj dolazi do narušavanja ravnoteže između proizvodnje i potrošnje djelatne snage te frekvencija sustava odstupa od nazivne vrijednosti. Regulacijom te frekvencije se održava ravnoteža između proizvodnje i potrošnje djelatne snage u realnom vremenu [14].

### **Crni start:**

Naziva se još i pokretanje iz beznaponskog stanja, to je mogućnost elektrane da se dovede u nazivno pogonsko stanje bez dodatnog napajanja iz električne mreže. Prilikom ispada nekog dijela mreže iz sinkronizma, proizvodne jedinice pretrpljuju promjene opterećenja. Tada regulacija agregata djeluje na način da znatnija opterećenja iznad vlastitih potreba svlada na siguran način. Takav otočni pogon može trajati više sati [14].

### **Rotirajuća pričuva:**

Omogućuje postojanje neopterećenih proizvodnih kapaciteta, tj. generatora koji ne rade punim snagama. Istodobno su sinkronizirani na mrežu i mogu trenutno reagirati ukoliko se zbog ispada nekog elementa prijenosa ili neke proizvodne jedinice pojavi neravnoteža između proizvodnje i potrošnje. Ovi generatori mogu biti u potpunosti raspoloživi u periodu od nekoliko minuta [14].

**Primarna regulacija napona:**

Ne dozvoljava sustavu dolazak u stanje naponskog sloma ili značajno opadanje napona.

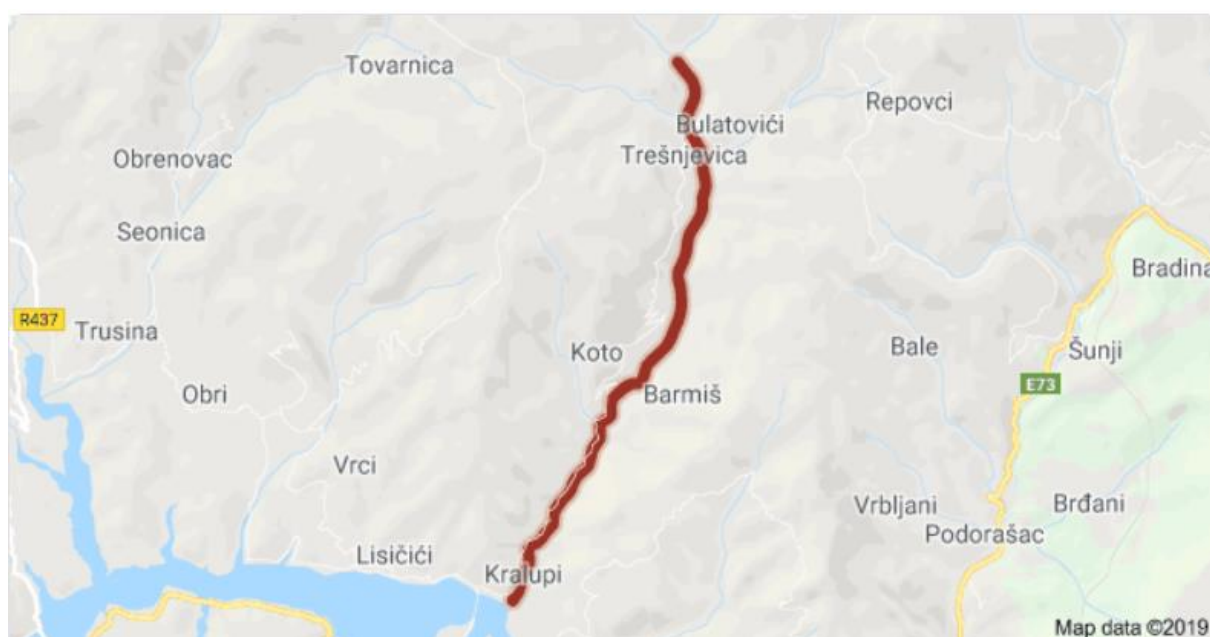
**Vozni red:**

S obzirom da u elektroenergetskom sustavu postoji velik broj potrošača koji električnu energiju na način koji njima najviše odgovara i vrijeme koje njima najviše odgovara, ukupna potrošnja električne energije u sustavu se konstantno mijenja. Zadatak elektroenergetskog sustava jest da se prilagodi zahtijevima svojih potrošača, a to čini formiranjem voznog reda, odnosno dijagrama opterećenja [15].

## 2.5. Kraljušćica 1 i 2

Kraljušćica 1 i 2 su derivacijske hidroelektrane koje se nalaze na rijeci Kraljušćici pokraj Konjica, BiH. Ova rijeka izvire na području planine Bitovnje, širine je 2-4 metra, a pokraj mjesta Kralupi ulijeva se u Jablaničko jezero. Tok rijeke je tipični planinski s neujednačenim vodenim protokom. Dubina rijeke je između 30 i 60 centimetara [16].

Na Kraljušćici su izgrađene dvije male hidroelektarne derivacijskog tipa, vlasnik je tvrtka Amitea d.o.o. Mostar.



*Slika 2.8. Lokacija rijeke Kraljušćice*

## Kraljušćica 1:

Osnovni tehničko-energetski parametri male hidroelektrane "Kraljušćica 1" u vlasništvu "AMITEA-II" d.o.o. Mostar za koju je izdata dozvola za rad za proizvodnju električne energije'

Red. br.	HIDROELEKTRANA (HE)	Jedinica	Tehnički parametri
1	Naziv elektrane		mHE "Kraljušćica 1"
2	Vlasnik elektrane		"AMITEA-II" d.o.o. Mostar
3	Lokacija elektrane		naselje Kralupi opština Konjic
4	Rijeka na kojoj se nalazi		na vodotoku rijeke Kraljušćica
5	Tip elektrane		derivaciona
6	Datum izdavanja uporabne dozvole		3.12.2015.
7	Način upravljanja (automatsko/ručno)		automatsko
8	Ima li mogućnost daljinskog upravljanja		da
9	Tip turbine		Pelton vertikalna
10	Proizvođač turbine		Koessler Austrija
11	Snaga turbine	(kW)	3.323
12	Tip generatora		sinkroni - trofazni
13	Proizvođač generatora		Indar Španija
14	Napon generatora	(kV)	6,3
15	Broj agregata	kom.	1
16	Instalisana snaga naznačena u Ugovoru o koncesiji	(kW)	2.120
17	Instalisana prividna snaga	(kVA)	4.230
18	Instalisana aktivna snaga	(kW)	3.465
19	Nazivni faktor snage		0,95
20	Maksimalna jalova snaga	(kVAr)	631
21	Instalisani protok	(m <sup>3</sup> /sec)	1,80
22	Minimalna snaga agregata	(kW)	316
23	Godišnja proizvodnja električne energije predviđena Ugovorom o koncesiji	(MWh)	8.720
24	Godišnja proizvodnja na pragu (projektovana)	(MWh)	12.500
25	Godišnja proizvodnja na pragu (bilanca na osnovi 70 % vjerojatnoće dotoka)	(MWh)	9.375
26	Vrijeme godišnjeg rada mHE (projektirano)	sati	6.720
27	Ukupni nominalni stupanj korisnosti mHE	(%)	89
28	Energija dobivena od 1 m <sup>3</sup> vode	(kWh)	0,456
29	Količina vode za 1 kWh električne energije	(m <sup>3</sup> )	2,89
30	Ekološki prihvatljiv protok (E.P.P.)	(m <sup>3</sup> /sec)	0,17
31	Blok transformator – nominalna snaga	(kVA)	4.000
32	Vlastita potrošnja s odcjepa (projektirana)	(kWh)	2.880
33	Potrošnja iz mreže (projektirana)	(kWh)	2.880
TLAČNI CJEVOVOD			
34	Tip vodozahvata		tirolski
35	Kota vodozahvata	m.n.m.	880,32
36	Dužina cjevovoda	m	3.741,37
37	Promjer cjevovoda	mm	1.100/1.000
38	Materijal cjevovoda		GRP, čelik
39	Izvedba (nadzemni/podzemni)		podzemni
40	Bruto pad	m	222,98
41	Kota turbinskog zatvarača	m.n.m.	657,34

Slika 2.9. Karakteristike HE "Kraljušćica I" [5]

## Kraljušćica 2:

### PRILOG 2.

Osnovni tehničko-energetski parametri male hidroelektrane "Kraljušćica 2" u vlasništvu "AMITEA-II" d.o.o. Mostar za koju je izdata dozvola za rad za proizvodnju električne energije

Red. br.	HIDROELEKTRANA (HE)	Jedinica	Tehnički parametri
1	Naziv elektrane		mHE "Kraljušćica 2"
2	Vlasnik elektrane		"AMITEA-II" d.o.o. Mostar
3	Lokacija elektrane		naselje Kralupi opština Konjic
4	Rijeka na kojoj se nalazi		na vodotoku rijeke Kraljušćica
5	Tip elektrane		derivaciona
6	Datum izdavanja uporabne dozvole		3.12.2015.
7	Način upravljanja (automatsko/ručno)		automatsko
8	Ima li mogućnost daljinskog upravljanja		da
9	Tip turbine		Pelton vertikalna
10	Proizvođač turbine		Koessler Austrija
11	Snaga turbine	(kW)	4.995
12	Tip generatora		sinkroni - trofazni
13	Proizvođač generatora		Indar Španija
14	Napon generatora	(kV)	6,3
15	Broj agregata	kom.	1
16	Instalisana snaga naznačena u Ugovoru o koncesiji	(kW)	4.010
17	Instalisana prividna snaga	(kVA)	4.995
18	Instalisana aktivna snaga	(kW)	4.478
19	Nazivni faktor snage		0,95
20	Maksimalna reaktivna snaga	(kVAr)	948
21	Instalirani protok	(m <sup>3</sup> /sec)	2,30
22	Minimalna snaga agregata	(kW)	475
23	Godišnja proizvodnja električne energije predviđena Ugovorom o koncesiji	(MWh)	16.980
24	Godišnja proizvodnja na pragu (projektirana)	(MWh)	18.950
25	Godišnja proizvodnja na pragu (bilanca na osnovi 70 % vjerojatnoće dotoka)	(MWh)	13.265
26	Vrijeme godišnjeg rada mHE (projektirano)	sati	6.864
27	Ukupni nominalni stupanj korisnosti mHE	(%)	89
28	Energija dobivena od 1 m <sup>3</sup> vode	(kWh)	0,572
29	Količina vode za 1 kWh električne energije	(m <sup>3</sup> )	1,745
30	Ekološki prihvatljiv protok (E.P.P.)	(m <sup>3</sup> /sec)	0,283
31	Blok transformator – nominalna snaga	(kVA)	5.000
32	Vlastita potrošnja s odcjepa (projektirana)	(kWh)	2.880
33	Potrošnja iz mreže (projektirana)	(kWh)	2.880
TLAČNI CJEVOVOD			
34	Tip vodozahvata		tirolski
35	Kota vodozahvata	m.n.m.	652,49
36	Dužina cjevovoda	m	2.226,00
37	Promjer cjevovoda	mm	1.100
38	Materijal cjevovoda		GRP, čelik
39	Izvedba (nadzemni/podzemni)		podzemni
40	Bruto pad	m	258,59
41	Kota turbinskog zatvarača	m.n.m.	393,90
42	Tip turbinskog zatvarača		leptirasti

Slika 2.9. Karakteristike HE "Kraljušćica I" [5]


Sustav HE Kraljušćica se nalazi na vodotoku dužine 9 km. Gornja kota vode iznosi 878.23 MNM a donja 291,00 MNM. Ukupna projektna snaga iznosi 10.835 MW a ukupna projektna energija iznosi 55546 GWh. Ukupna dužina tlačnih cjevovoda iznosi 8410.3 m [17].

U svrhu spajanje ovih dviju hidroelektrana na električnu mrežu, izgrađena je 35kV veza TS 110/35/10kV-RT 35kV Kraljušćica, dužine 10.8 km [18].

### 3. UMJETNA INTELIGENCIJA

#### 3.1. Podjela umjetne inteligencije

U ovom poglavlju najviše će riječi biti o neuronskim mrežama, odnosno o dubokom učenju. Navedeni pojmovi su dio umjetne inteligencije čija se osnovna podjela može vidjeti na sljedećoj *Slici 3.1.* :



*Slika 3.1. Osnovna podjela umjetne inteligencije [19]*

Prethodno prikazana podjela umjetne inteligencije naizgled je jednostavna. U stvarnosti, svako od ovih područja je ogromno i skoro je nemoguće detaljno savladati svako od njih. Ne postoje čvrste i jasne granice između područja pa se često događaju situacije u kojima različite osobe isti zadatak svrstavaju u različite podgrupe umjetne inteligencije. Detaljno razjašnjavanje tih problema bi samo za sebe moglo biti tema neke knjige tako da nema smisla trošiti previše prostora na to u ovome radu, ali ima smisla općenito pokušati približiti smisao svake od podgrupa.

**Umjetna inteligencija (eng. *Artificial Intelligence*):**

Umjetna inteligencija nastoji računalima dati mogućnost razmišljanja u smislu osposobljavanja stroja da izvršava zadatke koje može izvršiti čovjek. Može se reći da je umjetna inteligencija tehnika koja omogućuje strojevima oponašanje ljudi i njihove prirode.

**Strojno učenje (eng. *machine learning*):**

*“Sposobnost učenja računalnog sustava bez da je isti eksplicitno isprogramiran za svaki mogući zadatak. Dodavanjem novih podataka ovakvi programi ili algoritmi mogu poboljšavati svoje djelovanje, odnosno mogu učiti uz pomoć statistike analize. Primjer ovakvog programa je program za prepoznavanje obrazaca na slikama. Danas je strojno učenje jedno je od najaktivnijih i najzanimljivijih područja računalne znanosti, ponajviše zbog brojnih mogućnosti primjene koje se protežu od raspoznavanja uzoraka i dubinske analize podataka do robotike, računalnog vida, bioinformatike i računalne lingvistike” [20].*

**Duboko učenje (eng. *deep learning*):**


*“Duboko učenje je grana strojnoga učenja temeljena na predstavljanju podataka složenim reprezentacijama na visokom stupnju apstrakcije do kojih se dolazi slijedom naučenih nelinearnih transformacija.. Metode dubokog učenja svoju primjenu pronalaze u važnim područjima umjetne inteligencije poput računalnog vida, obrade prirodnog jezika, razumijevanja govora i zvučnih signala, kao i u bioinformatici” [21].*

### **3.2. Biološke neuronske mreže**

Neuronske mreže, koje su dio dubokog učenja, su ono na čemu se temelji ovaj rad. Cilj umjetnih neuronskih mreža je simuliranje rada bioloških neuronskih mreža. Zato bi za početak bilo korisno saznati osnove funkcioniranja bioloških neuronskih mreža.

Neuron ili neuronska stanica je električki podražena stanica koja obrađuje i prenosi informacije putem električnih i kemijskih signala. Signali između neurona se prenose preko sinapsi. Međusobno spojeni neuroni čine neuronsku mrežu. Oni čine glavnu komponentu građe mozga i leđne moždine, tj. središnjeg živčanog sustava. Jedna od definicija živčanog sustava je ta da je živčani sustav mreža specijaliziranih stanica koje šalju, prenose ili primaju informacije vezane za živi organizam i njegovu okolinu. Obradujući te informacije, živčani sustav potiče reakcije u drugim dijelovima tijela [22].

Funkcioniranje živčanog sustava je prikazano na *Slici 3.2.* :



Slika 3.2. Jednostavni prikaz funkcioniranja biološkog živčanog sustava [23]

*“Osjetni organ, u ovom slučaju oko, prima informaciju u obliku svjetlosnog signala. Putem osjetnih receptora koji su dio perifernog živčanog sustava, signal putuje do mozga. Interneuroni u mozgu, koji su dio središnjeg živčanog sustava, analiziraju dobiveni signal te ga šalju prema odgovarajućem motoričkom neuronu koji dalje upravlja određenim dijelom tijela. U ovom slučaju je to šaka, za koju možemo zamisliti da se našla u posudi prljave vode, te smo je nakon te spoznaje maknuli iz posude” [23].*

Postavlja se pitanje, kako mozak prepoznaje da su određeni signali baš signali za funkciju osjeta vida ili za bilo koju drugu funkciju? Naime, mozak živih bića se sastoji od velikog broja neruona koji se međusobno povezuju shodno ulaznim signalima koji su posljedica raznih podražaja iz okoliša. Mozak uspostavljanjem međuneuronskih mreža pohranjuje informacije o pristiglom podražaju i tako formira biološku neuronsku mrežu na temelju koje dobiva sposobnost povezivanja uzroka i posljedica. Odnosno, dobiva sposobnost formiranja generalizacijskog modela na osnovu kojega uz pomoć odgovora na već poznata pitanja može davati odgovore na nepoznata pitanja. To se također zove process učenja, stjecanje iskustva ili treniranje neuronskih mreža [24].

Cijeli proces može se svesti na tri koraka:

- Primanje ulaznog signala, tj. ulaznih informacija
- Obrada ulaznih signala, tj. ulaznih informacija
- Stvaranje izlaznog signala


### **3.3. Umjetne neuronske mreže općenito**

Umjetne neuronske mreže su nastale po uzoru na biološke neuronske mreže. UNM-e su paralelni, često masivni, distribuirani sustav za obradu podataka. Kao i biološke neuronske mreže, sastoje se od određenog broja međusobno povezanih neurona koji imaju sposobnost učenja, odnosno, obavljanja određenih generalizacijskih funkcija. Umjetni neuroni su jednostavna matematička aproksimacija bioloških neurona, izrađuju se kao elementi računalnog programa ili kao silicijski fizički elementi (elektroničke komponente). Kao takvi su alternativa klasičnim matematičkim i računalnim metodama. Najčešće se primjenjuju u neurologiji, matematici, statistici, fizici, računarstvu, modeliranju, raspoznavanju uzoraka, obradi signal, vođenju sustava i drugdje [24].



### 3.4. Perceptron, Višeslojni perceptron, sigmoidni neuron

#### 3.4.1. Perceptron



Slika 3.2. Model umjetnog neurona [24]

Jednoslojni perceptron, odnosno neuron, ima niz ulaza  $u_m$  kojima su pridijeljeni težinski faktori  $w_m$ . Član  $p_k$  označava zbroj otežanih ulaza i definira se *Izrazom* (3.2.) . Član  $\varphi(p)$  je aktivacijska funkcija neurona. *Izrazi 1 i 2* predstavljaju matematički model umjetnog neurona čiji su ulazi označeni s  $u_k$ , a vrijednosti težinskih koeficijenata su označene s  $w_k$ . Umjetni neuron u  $k$ -tom koraku računa odziv  $o_k$  prema *Izrazu* (3.2.) . Vrijednost odziva ovisi o aktivacijskoj funkciji [24].

$$o_k = \varphi(p) \quad (3.1.)$$

$$p_k = \sum_{n=0}^m (w_k \cdot u_k)_n \quad (3.2.)$$


Pojednostavljeno, kada zbroj ulaznih signala prijeđe određenu razinu koja se zove “*bias*” , neuron se aktivira.

O tome kako perceptron radi, može se razumjeti na primjeru logičke ILI funkcije.

Perceptron dijeli ulazne podatke u dvije grupe, one koji aktiviraju izlaznu funkciju i one koji ne aktiviraju izlaznu funkciju.  $X_1$  i  $X_2$  su ulazni podatci a  $y$  je izlazni podatak koji neuron treba dati.

Tablica 3.1. ILI logička funkcija

$X_1$	$X_2$	$y$
0	0	0
0	1	1
1	0	1
1	1	1



Slika 3.3. Funkcija razdvajanja

Odabirom vrijednosti parametara mreže, tj. težinskih i “bias” vrijednosti, dobivena je jednadžba pravca, grafički prikazana na Slici 3.3. . Ovim pravcem su četiri moguće ulazne kombinacije podataka razdvojene u dvije grupe.


S jedne strane pravca su ulazni podatci koji aktiviraju izlaznu funkciju, to su ulazi  $P_2(0,1)$ ,  $P_3(1,0)$  i  $P_4(1,1)$ . S druge pak strane linije je ulazni podatak koji ne aktivira izlaznu funkciju. To je ulaz  $P_1(0,0)$ .

U ovom slučaju podatci su razdvojeni linijom, u  $n$ -dimenzionalnom prostoru podatci se razdvajaju  $n-1$  dimenzionalnom ravninom, ali smisao ostaje isti – kombinacijom parametara mreže i aktivacijske funkcije razdvojiti ulazne podatke na one koji aktiviraju perceptron i one koji ga ne aktiviraju. Nije moguće svaki put ulazne podatke razdvojiti jednostavnim pravcem. Podatci koje se može razdvojiti na ovaj način su linearno razdvojitivi podatci [25].

Primjer skupa podataka nerazdvojivih linijom je skup ulaznih podataka za XOR logičku funkciju. Na sljedećoj *Slici 3.4.* se vidi kako je nemoguće jednim pravcem na dva dijela razdvojiti ulazne podatke koji aktiviraju izlaz od ulaznih podataka koji ga ne aktiviraju. Taj problem se rješava višeslojnim mrežama [26], [27], [28].

*Tablica 3.2. XOR logička funkcija*

$X_1$	$X_2$	$y$
0	0	0
0	1	1
1	0	1
1	1	0



*Slika 3.4. Neuspješno razdvajanje ulaznih podataka XOR logičke funkcije*


### 3.4.2. Sigmoidalni perceptron, ostale aktivacijske funkcije

Problem XOR logičke funkcije se može riješiti višeslojnim perceptronom sa sigmoidalnim aktivacijskim funkcijama. Perceptroni na izlazu mogu imati vrijednost izraženu samo u cijelim brojevima. Ukoliko tijekom treniranja mreže sastavljene od perceptrona promijenimo pojedine težinske faktore, promjene izlaznih vrijednosti pojedinih neurona će biti skokovite. Neuroni će se ponašati binarno, ili će biti potpuno aktivirani i davat će na izlazu maksimalnu vrijednost ili neće biti aktivirani pa će davat minimalnu vrijednost. Nedostatak postupnog prijelaza između neaktivnog i aktivnog stanja otežava podešavanje mreže, tj. proces učenja mreže. Postavlja se


pitanje, kako mijenjati težinske faktore a da se vrijednosti ostalih perceptrona i konačna vrijednost mreže ne mijenja skokovito? Odgovor leži u perceptronu sa sigmoidalnom funkcijom. Sigmoidalna funkcija je prikazana na *Slici (d)*.

Za velike pozitivne ulaze, vrijednost izlaza je blizu vrijednosti jedan i neuron je aktiviran. Za velike negativne brojeve, izlazna vrijednost je približna vrijednosti nula i neuron nije aktiviran. Za ulazne vrijednosti koje su oko nule, izlazna vrijednost je približna vrijednosti 0.5. Zahvaljujući ovome svojstvu mreža, može se zaključiti koliko je jako neki neuron aktiviran, tj. može se procijeniti kolika je važnost nekog neurona. Osim toga, sigmoidalna funkcija je nelinearna funkcija a s nelinearnim funkcijama mogu se aproksimirati druge nelinearne funkcije. Što mreža ima na raspolaganju više neurona čija je aktivacijska funkcija nelinearna, lakše će aproksimirati zadanu nelinearnu funkciju. Ali će joj trebati više vremena za to. Na *Slici 3.5.* su prikazane neke od ostalih aktivacijskih funkcija neurona. Linearna aktivacijska funkcija nema ovu mogućnost jer kombinacijom linearnih funkcija kao rezultat uvijek dobijemo opet linearnu funkciju.


(a)




(b)



(c)



(d)



*Slika 3.5. Aktivacijske funkcije: (a) linearna, (b) ograničena linearna, (c) unipolarna sigomidalna, (d) bipolarna sigomoidalna [24]*

Shematski, sigmoidalni perceptron izgleda isto kao i perceptron. Dakle, ima ulaze od  $X_1$  do  $X_n$ , no, njegova izlazna vrijednost  $y$  može imati bilo koju realnu vrijednost, npr. 0.67975. Kao i perceptron, sigmoidalni perceptron ima težinske faktore  $W$  za svaki ulaz. Te “*bias*” vrijednost  $b$ .


Izlaz prikazujemo kao  $\varphi(w \cdot u + b)$ , gdje je  $\varphi$  is sigmoidna funkcija definirana kao:

$$\varphi(p) \equiv \frac{1}{1+e^{-p}} \quad (3.3.)$$

### 3.4.3. Višeslojni Perceptron

Višeslojni perceptron (MLP) je statička unaprijedna neuronska mreža (*eng. feedforward neural network*). Višeslojni perceptron je kombinacija zajedno utkanih slojeva perceptrona. Izlazi prvog sloja su ulazi drugog sloja, izlazi drugog su ulazi trećeg i tako dalje do konačnog, izlaznog sloja. Slojevi između ulaznog i izlaznog sloja se zovu skriveni slojevi. Dakle, u općem slučaju, višeslojni perceptron se može sastojati od najmanje 3 sloja, ulaznoga, skrivenoga i izlaznoga. Veze između neurona mogu biti razne, u općem slučaju svaki neuron jednog sloja je povezan sa svakim neuronom idućega sloja. Na *Slici 3.6.* ispod prikazan je primjer višeslojnoga perceptrona koji je ujedno rješenje za problem XOR logičke funkcije.

U *Tablici 3.3.* su prikazane kombinacije ulaza koje dovodimo na neuronsku mrežu sa *Slike 3.6.* i očekivane izlazne vrijednosti.



*Slika 3.6. Višeslojni perceptron za XOR funkciju*

Ukoliko ovoj mreži pridijelimo prikladne parametre pomoću kojih mreža može oponašati XOR funkciju, može se primijetiti da  $h_1$  neuron funkcionira kao OR logički operator. Izlazna


vrijednost neurona  $h_1$  je 0 za ulazni par  $X_1=0$  i  $X_2=0$ , a za sve ostale kombinacije izlazna vrijednost mu je 1.

Neuron  $h_2$  funkcionira kao NAND logički operator. Kombinacijom ta dva operatora dobiven je XOR operator. To se može vidjeti u *Tablici 3.3.* .

*Tablica 3.3. Način dobivanja XOR logičke funkcije*

$X_1$	$X_2$	$h_1 = \text{OR}$	$h_2 = \text{NAND}$	$h_1 * h_2 = \text{XOR}$
0	0	0	1	0
0	1	1	1	1
1	0	1	1	1
1	1	1	0	0

Na *Slici 3.7.* je prikazano kako ovakva višeslojna mreža utječe na podjelu ulaznih podataka u dvodimenzionalnoj ravni. Svaki neuron skrivenoga sloja stvara svoju ravan, tj. svoju liniju podjele ulaznih podataka. Dakle, u tom prostoru nastaju četiri ravni, u ravninama određenima neuronom  $h_2$  se s jedne strane nalaze parovi ulaznih podataka  $P_1(0,0)$ ,  $P_2(0,1)$ ,  $P_3(1,0)$  a s druge strane par  $P_4(1,1)$ . Podjela je označena plavom bojom. U ravninama određenima neuronom  $h_1$  se s jedne strane nalaze parovi ulaznih podataka  $P_2(0,1)$ ,  $P_3(1,0)$  i  $P_4(1,1)$  a s druge strane par  $P_1(0,0)$ . Podjela je označena narančastom bojom. Izlazni neuron nalazi presjek između ove dvije podjele koje čine neuroni skrivenoga sloja i tako mreža poprima značajke XOR logičke funkcije.



*Slika 3.7. Uspješno razdvajanje ulaznih podataka XOR logičke funkcije*

Opisani primjeri daju intuitivni uvid u osnove funkcioniranja višeslojnih umjetnih neuronskih mreža.

### **3.5. Svojstva, mogućnosti i vrste umjetnih neuronskih mreža**

Duboko učenje, neuronske mreže, odnosno, općenito umjetna inteligencija posljednjih godina bilježi veliki rast popularnosti. Kad je riječ o popularnosti, tijekom povijesti je umjetna inteligencija imala uspone i padove a razlozi zašto je baš posljednjih godina doživjela izraziti rast bit će objašnjeno na stranicama koje slijede.

#### **1. Dostupnost podataka**

U današnje vrijeme, za razliku od prije nekoliko desetljeća, dostupne su ogromne baze podataka koje se mogu iskoristiti za modeliranje i testiranje umjetnih neuronskih mreža.

#### **2. Računalna moć**

Ogromna količina podataka je beskorisna ukoliko ne postoje računala dovoljno dobrih performansi da obrađuju te podatke dakako u razumnom vremenu. Eksponencijalni rast računalnih performansi pridonosi uporabljivosti umjetne inteligencije u stvarnosti.

#### **3. Algoritmi**

Napredak u algoritmima omogućuje bržu obradu podataka i korištenje veće količine podataka.

#### **4. Marketing**

Zanimljivi projekti poput autonomnih vozila, humanodinog robota Sophia [29] itd., značajno su proširili popularnost umjetne inteligencije čime je ona postala marketinški puno privlačnija i samim tim su porasla ulaganja u nju.

Umjetne neuronske mreže su se pokazale korisnim kod problema koji su dinamični i nelinearni, za razliku od konvencionalnih tehnika koje su često ograničene linearnostima, neovisnošću varijabli... Konvencionalna “serijska” računala adresiraju memorijske lokacije te na temelju tih adresa “dohvaćaju” podatke koji su im potrebni. “Dohvaćene” podatke obrađuje CPU, a rezultati operacija se spremaju u memorijske registre. Ove akcije su determinističke, imaju svoj red, svoju logiku i operacije se mogu logički relativno lako pratiti. Umjetne neuronske mreže nemaju ta svojstva, ne postoji CPU nego perceptroni koje možemo interpretirati kao male procesorske jedinice koje obavljaju jednostavne logičke operacije i sve zajedno paralelno obrađuju dobivene podatke. Takav način obrade podataka UNM-i omogućuje rad čak i ako se

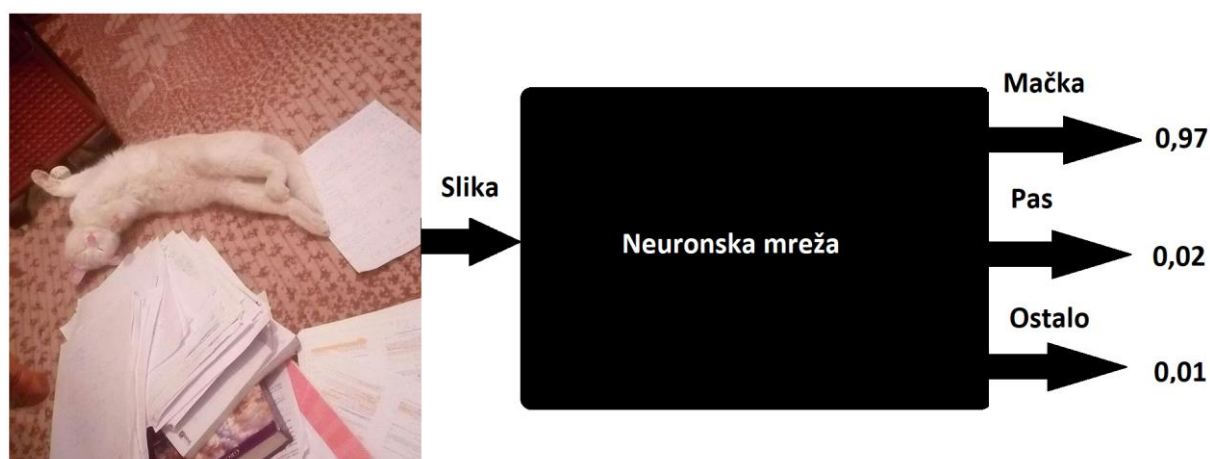
jedan njen dio pokvari. To je upravo i najveća prednost umjetnih neuronskih mreža u odnosu na konvencionalna računala.

UNM-e najbolje funkcioniraju pri modeliranju sustava sa visokim pragom tolerancije pogreške, odnosno sustava čiju funkciju model može aproksimirati sa relativnim stupnjem točnosti. UNM-e se zbog toga još nazivaju i univerzalnim aproksimatorima [24], [30].

Shodno navedenome, neuronske mreže je dobro primjenjivati [30]:

- Za otkrivanje pravilnosti, logičkih obrazaca unutar uzoraka podataka
- Kada postoji velika količina varijabla i ulaznih podataka
- Za otkrivanje veze između varijabla koje nisu jasno razumljive
- Za pojave koje se teško opisuju konvencionalnim metodama

Jedno od najvećih ograničenja neuronskih mreža je to što su neuronske mreže najčešće “crne kutije”. Što znači da se ne zna što se točno odvija u samoj mreži; znaju se samo ulazni podatci i izlazni rezultat. Ako se npr. u mrežu ubace podatke o psu a mreža kaže da se radi o automobilu, vrlo je teško razumjeti što je točno uzrok takve pogreške. Ovo uzrokuje i neke etičke probleme koji usporavaju širenje primjene umjetnih neuronskih mreža, npr. ukoliko banka na temelju rezultata neuronskih mreža odbije klijenta koji želi podignuti kredit, postavlja se pitanje koliko je etično odbiti klijenta na temelju rezultata računala bez da je poznat jasan razlog zbog kojega je računalo donijelo takvu odluku.



Slika 3.8. UNM kao “Black box” sustav

Neki od problema svojstvenih za umjetne neuronske mreže:

- Predviđanje nasumičnih brojeva
- Faktoriranje velikih cijelih brojeva (eng. *Factoring large integers*)



- Određivanje je li veliki cijeli broj prost ili složen.
- Dekriptiranje kvalitetno enkriptiranih podataka.
- Pretreniranje (*eng. Overfitting*)
- Podtreniranje (*eng. Underfitting*)

### 3.5.1. Vrste neuronskih mreža

Strukture UNM-a se mogu razlikovati prema:

- tipu neurona od kojih su građene,
- po načinu na koji su neuroni povezani
- i/ili po algoritmu koji se koristi za podešavanje međuneuronskih veza [24].

Struktura koja se najčešće koristi jest višeslojni perceptron (MLP), druge strukture su Najpoznatiji i najčešće korišteni tip umjetne neuronske mreže je višeslojni perceptron (MLP), neuronske mreže s prijenosnom funkcijom radijalne baze (*engl. radial basis function, RBF*), samoorganizirajuće mape (SOM), GRNN (*engl. generalized regression neural networks*), RNN (*engl. recurrent neural networks*), SVM (*engl. support vector machines*), TNN (*engl. temporal neural networks*), *neuro-fuzzy*. Njihova temeljna podjela je na statičke i dinamičke neuronske mreže.

Glavne vrste algoritama za učenje su nadzirani i nenadzirani a glavni tipovi topologije mreže su unaprijedna i unazadna. Općenito, podjela tipova neuronskih mreža je opširna, u ovom radu će biti objašnjeni samo pojmovi bitni za ovaj rad.

#### Nadzirano učenje:

Kod nadziranoga učenja, rezultati koje mreža treba dati za neki set ulaznih podataka su samoj mreži unaprijed poznati i dani su joj obliku podataka za trening. Pomoću njih, umjetna neuronska mreža uvježbava prilagodbu svojih parametara. Nakon treninga, mreži se upućuju samo ulazni podatci, bez poznatih željenih izlaznih podataka. Zadatak mreže je da na temelju prijašnjeg treninga, odredi vrijednosti svojih parametara tako da uspješno aproksimira zadanu funkciju. Nadzirano učenje je upravo ono na čemu se temelji ovaj rad [31].

**Feedforward/unaprijedna mreža:**

Kod ovakvih mreža ne postoje “povratne veze” između slojeva pomoću kojih se podatci vraćaju prema nazad i ciklički kruže kroz slojeve. Ovakve mreže imaju brz odgovor na ulazne podatke.

**Feedback/unazadna mreža:**

Kod ovog tipa mreža postoje “povratne veze”, tj. postoji cikličko kretanje podataka kroz slojeve mreže. Kod ovakvih mreža može se dogoditi dugotrajno iteriranje podataka kroz mrežu prije nego što se dobije izlazni signal.

**Nenadzirano učenje:**

Kod nenadziranog učenja mreža tijekom treninga nema uvid u željene rezultate.

## **4. UMJETNE NEURONSKE MREŽE U HIDROLOGIJI**

### **4.1. Osnovni zadatci kod formiranja UNM-e u hidrologiji**

Osnovni zadatci u formiranju neuronskog modela se svode na određivanje strukture mreže koja će biti korištena, zatim se određuju algoritmi za treniranje mreže i funkcija cilja koja se minimizira tijekom treniranja. Optimalna struktura mreže podrazumijeva optimalan broj neurona. Određivanje broja ulaznih neurona jest određivanje broja članova ulaznog vektora. Kada je riječ o formiranju modela vremenske serije, potrebno je odrediti i optimalan broj članova ulaznog vektora, u ovome radu taj broj se naziva “*delay*”. Ukoliko postoji više ulaznih varijabli, potrebno je ispitati utjecaj svake od njih na izlaznu varijablu. Ispitivanje tih utjecaja vrši se statističkom i grafičkom analizom podataka. Osim određivanja optimalnog broja ulaza, određuje se i optimalan broj skrivenih neurona, tj. optimalna struktura mreže. Broj izlaznih neurona je ovisan o broju koraka za koji se radi predviđanje. Najčešće se koristi jedan neuron čak i u slučaju predviđanja više koraka unaprijed [24].

### **4.2. Hidrološki sustavi**

Hidrološki sustavi su izrazito složeni sustavi s brojnim varijablama čiji je međusobni odnos najčešće nelinearan. Kruženjem u prirodi voda prolazi kroz mnoga agregatna stanja. Tekuća voda isparavanjem prelazi u plinovito stanje gdje se zadržava u, najčešće, višim slojevima atmosfere a zatim se može kondenzirati i pasti na zemlju opet u tekućem stanju, ili u krutom stanju u obliku tuče ili snijega. I na samom tlu voda može mijenjati agregatna stanja, tekuća voda i snijeg se mogu pretvarati u led, led i snijeg se mogu vraćati u stanje tekuće vode. Također, voda se može upijati u tlo ili otjecati podzemnim kanalima, potonje posebno vrijedi za krška područja te se može zadržavati u biljkama. Svi navedeni procesi dodatno ovise o temperaturi, snazi vjetra, nadmorskoj visini, tipu i vrsti tla, u konačnici i ljudskim aktivnostima kao što su poljoprivreda, izgradnje brana, kanala...

Prilikom rješavanja nekog hidrološkog problema uz pomoć umjetnih neuronskih mreža, valja pomno analizirati intenzitet utjecaja svake od navedenih pojava i na osnovu te analize formirati model s određenim brojem vrsta ulaznih varijabla i količinom podataka te određenom izlaznom

varijablom koju pokušavamo predvidjeti. Ne postoji metoda pomoću koje se lako mogu izabrati optimalne varijable i optimalna količina podataka. Izbor se svodi na metodu pokušaja i promašaja te odabira onoga modela koji je dao najbolje rezultate [24].

Nizom drugih istraživanja pokazalo se da neuronske mreže daju bolje rezultate od klasičnih fizikalnih i statističkih modela. Pri tome su i jednostavnije za primjenu. Veća točnost je posljedica sposobnosti aproksimacije nelinearnih funkcija.

### 4.3. Algoritmi za treniranje

Bilo da je riječ o jednostavnom perceptronu ili mnogo kompliciranijoj višeslojnoj umjetnoj neuronskoj mreži, potreban je sustavan pristup pomoću kojega će se određivati poželjni parametri neke mreže. Sustavan pristup se ostvaruje razvojem algoritama za treniranje pomoću kojih umjetne neuronske mreže uče [32].

Postupak treniranja mreže je iterativni postupak podešavanja parametara mreže, odnosno težinskih faktora i “*bias*” vrijednosti. Taj postupak se odvija prema određenom algoritmu čiji je cilj odrediti takve parametre mreže za koje će pogreška, odnosno funkcija cilja, biti najmanja [24].

Na samom početku UNM nema dostupne informacije o načinu rada sustava koji se modelira te ne poznaje međusobne odnose među varijablama. UNM upoznaje sustav tijekom, ranije spominjanog, postupka treniranja [24].

Bez obzira koji algoritam za učenje upotrijebili, temeljni koraci za izgranju neuronske mreže su vrlo slični i svode se na sljedeće:

1. Specificirati i dobro razumjeti zadani problem, odrediti ulazne vrijednosti i očekivane izlazne vrijednosti
2. Iskušati najjednostavniji oblik mreže za kojeg procijenimo da bi mogao funkcionirati
3. Pokušati pronaći prikladne parametre mreže, tj. parametre koji će uzrokovati željenu izlaznu vrijednost
4. Provjeriti da li mreža ispravno radi kada joj na ulaz dovedemo set novih, do tada nepoznatih podataka, tj. provjeriti koliko je mreža sposobna generalizirati
5. Ako mreža ne daje željene rezultate, vratiti se na korak 3

6. Ako mreža i dalje ne daje željene rezultate, vratiti se na korak 2
7. Ako mreža i dalje ne daje željene rezultate, vratiti se na korak 1

#### 4.3.1. Način rada algoritama

Nakon što se netrenirana mreža podraži, najvjerojatnije će dati odziv koji se razlikuje od željenoga odziva. Ta razlika se naziva pogreškom  $E$ . Pogreška je funkcija varijabli mreže. To se može izraziti Izrazom (4.1.):

$$E = f(w) \quad (4.1.)$$

Algoritam za učenje korigira varijable mreže ( $w$ ) kako bi kroz više iteracija pogrešku  $E$  minimizirao, odnosno kako bi mreža dala željeni odziv [24].

*“Algoritam za funkciju cilja ima postavljeno minimalno ili nulto odstupanje odziva mreže od željene vrijednosti, odnosno minimalnu ili nultu vrijednost pogreške. Pogreška, odnosno odstupanje mreže od željenog odziva se izražava preko funkcije cilja ( $E$ ), u tu svrhu se može koristiti različite izraze poput ukupne kvadratne pogreške (engl. sum of squared error, SSE), srednje kvadratne pogreške (engl. mean squared error, MSE), njenog korijena (engl. root mean squared error, RMSE), srednje apsolutne pogreške (engl. mean absolute error, MAE) ili neke druge funkcije koje u sebi nose informaciju o pogrešci” [24].*

Teško je precizno reći kada upotrijebiti neki tip algoritma za učenje, naime, izbor ovisi o tipu problema koji se pokušava riješiti. Ne postoji savršeni, svemoćni algoritam koji može riješiti svaki problem.

#### 4.3.2. Algoritmi korišteni u ovom radu

##### **Levenberg Marquardt:**

Levenberg - Marquardt (LM) algoritam se često koristi za rješavanje problema vezanih za nelinearne funkcije. Ova metoda je kombinacija dviju drugih metoda: gradijentnog spusta (*eng. gradient descent method*) i Gauss-Newtonovog algoritma.

Oba algoritma su iterativni algoritmi, što znači da iznova ponavljaju izračun dok ne dobiju željeno rješenje. Kod metode gradijentnog spusta (*eng. gradient descent method*) u svakoj iteraciji rješenje se poboljšava izborom vrijednosti parametara mreže zbog kojih se vrijednost funkcije smanjuje. Preciznije, kretanjem u smjeru najvećega spusta smanjuje se zbroj najmanjih kvadrata pogreške. Korak kretanja ovisi o tome koliko se blizu nalazi rješenje – što je rješenje dalje, korak je veći. Približavanjem rješenju, korak se smanjuje.

Kod Gaus-Newtonove metode se pretpostavi da je funkcija najmanjih kvadrata pogreške na nekom lokalnom intervalu kvadratna i zatim se traži minimum te kvadratne funkcije.

Kada je daleko od rješenja, LM algoritam se više ponaša kao algoritam gradijentnog spusta a kada su parametric mreže daleko od optimalnih. Kada su blizu optimalnih ponaša se više kao Gauss-Newton algoritam.

LM algoritam je relativno robustan, brže konvergira ka rješenju od Gauss-Newton algoritma, jednostavniji je za primjenu od Gauss-Newton algoritma. Algoritam može pronaći optimalno rješenje čak i kada je početna pretpostavka rješenja daleko od optimalnoga rješenja. Problemi s ovim algoritmom mogu nastati kod funkcija kojima na određenim intervalima vrijednost prve derivacije iznosi nula te kod modela s mnogo parametara (10 i više) pronalazak rješenja može teći iznimno sporo [33].

### **Bayesian:**

*Bayesian regularization* algoritam se može promatrati kao nadograđeni LM algoritma. Robustniji je; mreže koje koriste ovaj algoritam teško je pretrenirati; otporne su na “*overfitting*” stoga što ovakve mreže efikasnije koriste one parametre mreže koji više utječu na ponašanje mreže. Odnosno, može procijeniti broj parametara mreže koji su mreži potrebni (broj neurona) i ne samo njihov broj nego i njihove minimalne vrijednosti. To je moguće zbog tri posebna parametra algoritma uz čiju pomoć ovaj algoritam traži smjer kretanja prema najmanjoj vrijednosti pogreške, najmanjem broju parametara mreže i najmanjem broju neurona koji su mreži potrebni. Ima jako dobru sposobnost generalizacije, reducira potrebu testiranja različitog broja skrivenih slojeva u mreži. Slabije funkcionira ako je količina podataka za trening nedovoljna [34].

## 4.4. Modeli vremenske serije

Vremenska serija je niz podataka koji su bilježeni u nekom vremenskom intervalu s određenim periodom uzorkovanja.


Neuronski modeli vremenske serije vrše predviđanja na temelju vremenske serije samo jedne varijable. Poželjno je da vremenska serija bude što dulja i kontinuirana. Prilikom numeričke ocjene kvalitete, ovi modeli najčešće dobivaju visoke ocjene. No, grafičkom analizom se mogu uočiti razni problemi poput kašnjenja predviđanja modela za stvarnim događajem, predviđanja koja imaju nerealne vrijednosti. Kašnjenje se objašnjava nepostojanjem informacije koja bi nagovijestila naglu promjenu vrijednosti funkcije koju pokušavamo predvidjeti [24].

## 4.5. Strukture UNM-e

U ovom su poglavlju korištene dvije vrste struktura neuronskih mreža, NARX (eng. *Nonlinear autoregressive exogenous model*) i NAR (eng. *Nonlinear autoregressive model*).

Autoregresivni modeli (AR) predviđaju buduće ponašanje sustava na temelju ponašanja iz prošlosti. Ovi modeli se koriste za predviđanje kada postoji određena korelacija između vrijednosti vremenske serije i vrijednosti koje im prethode i slijede. Izlazna varijabla u nekom trenutku  $t$  je direktno ovisna o ulaznoj vremenskoj seriji i izlaznim varijablama iz prošlosti. Autoregresivni modeli su po svojoj prirodi stohastični, što znači da u sebi imaju sadržanu neku razinu neodređenosti, nasumičnosti. Zbog toga ne mogu biti posve točni nego do neke mjere aproksimiraju željenu funkciju [35].

Nelinarni autoregresivni modeli s vanjskim ulazom funkcioniraju na istome principu. Kao što samo ime kaže, koriste se za modeliranje nelinearnih sustava. Shema takvog modela je prikazana na sljedećoj Slici 4.1.:



Slika 4.1. NARX struktura

Kao što je ranije napisano, izlazna varijabla u nekom trenutku  $t$  je direktno ovisna o ulaznoj vremenskoj seriji  $x(t)$  i izlaznim varijablama iz prošlosti  $y(t-1, \dots, t-d)$ . Ovo možemo izraziti kao:


$$y(t) = f(x(t-1), \dots, (t-d), y(t-1), \dots, y(t-d)) \quad (4.2.)$$

Gdje “ $d$ ” označava broj koraka vraćanja u prošlost, engleski “*delay*”.

Sljedeća slika pokazuje nelinearni autoregresivni model. Kod ovoga modela, predviđanje izlazne vrijednosti  $y(t)$  se vrši samo na osnovu izlaznih vrijednosti iz prošlosti  $y(t-1, \dots, t-d)$ .

Ovo možemo izraziti kao:

$$y(t) = f(y(t-1), \dots, y(t-d)) \quad (4.3.)$$



Slika 4.2. NAR struktura

## 4.6. Ocjenjivanje modela

Ocjenjivanje modela možemo vršiti grafičkim i numeričkim metodama. Numeričke metode uz pomoć statističkih mjera kvalitete kvantiziraju odstupanje modela od stvarnih tj. željenih vrijednosti, mogu se podijeliti na apsolutne i relativne mjere kvalitete. Grafičke metode koristimo za vizualnu provjeru ročnosti modela.

Problem numeričkih metoda je nedostatak usuglašanih optimalnih mjera za ocjenu kvalitete modela. Različite mjere naglašavaju različita odstupanja pa ne postoji univerzalna numerička mjera kvalitete [24].



#### 4.6.1. Apsolutne mjere kvalitete modela

Apsolutne mjere kvalitete računaju razliku između odziva modela i željenih vrijednosti, odnosno odstupanje modela. Također mogu računati prosječno odstupanje modela. Kako bi se izbjeglo poništavanje pozitivnih i negativnih pogrešaka prilikom zbrajanja, računaju se apsolutne ili kvadratne vrijednosti pogrešaka zatim se kvadriraju ili usrednjuju.

Najkorištenije mjere kvalitete u hidrologiji su srednja kvadratna pogreška (MSE), korijen srednje kvadratne pogreške (RMSE), zbroj kvadratne pogreške (SSE) te srednja apsolutna pogreška (MAE). U ovom radu korištena je MSE i RMSE [24].

Srednja kvadratna pogreška (MSE), definirana *Izrazom (4.4.)*, temelji se na kvadratu pogreške. Računa prosječnu pogrešku za skup raspoloživih  $N$  članova.

$$MSE = \frac{1}{N} \sum_{s=1}^N (d_s - o_s)^2 \quad (4.4)$$

S obzirom da izražava odstupanje kvadratom jedinice, MSE (*eng. mean square error*) se češće koristi kao funkcija cilja dok se za ocjenjivanje modela hidrološkog sustava češće koristi RMSE (*eng. root mean square error*), *Izraz (4.5.)*, tj. korijen srednje kvadratne jednadžbe. Prikazana je izrazom:

$$RMSE = \sqrt{\frac{1}{N} \sum_{s=1}^N (d_s - o_s)^2} \quad (4.5.)$$

Nedostatak mjera kvalitete koje se koriste kvadriranjem pojedinačne pogreške je u tome što zbog toga velike pojedinačne pogreške poprimaju veći udio u ukupnim rezultatima pa tako većim odstupanjima daju veću važnost. Ako se apsolutne mjere koriste za usporedbu točnosti predviđanja različitih modela, tada uspoređivani modeli moraju biti testirani na istom tipu podataka, tj. moraju biti testirani pod istim uvjetima.

Apsolutne mjere kvalitete nisu dovoljne za određivanje opće granice prihvatljive i neprihvatljive točnosti predviđanja, opće granice određujemo uz pomoć relativnih mjera kvalitete [24].

#### 4.6.2. Relativne mjere kvalitete

Najčešće korištene relativne mjere kvalitete su Pearsonov koeficijent ( $r$ ), koeficijent neodređenosti ( $r^2$ ), koeficijent učinkovitosti (CE). Navedene mjere se temelje na korelaciji. U ovome radu korištena je mjera Pearsonovog koeficijenta ( $r$ ). Njegove vrijednosti se kreću u intervalu od -1 do +1. Pozitivne vrijednosti impliciraju pozitivnu korelaciju između ulaznih i izlaznih varijabla i označavaju njihovu proporcionalnu promjenu. Što znači da rastom jedne varijable raste i druga varijabla i obrnuto. Negativne vrijednosti koeficijenata impliciraju negativnu povezanost između ulaznih i izlaznih varijabla, odnosno, kada jedna varijabla raste druga pada i obrnuto [24].

*Tablica 4.1. Kategorizacija vrijednosti korelacijskog koeficijenta*

Korelacijski koeficijent	Linearna povezanost
$(\pm 0.25, \pm 0.5]$	Slaba
$(\pm 0.5, \pm 0.75]$	Umjerena
$(\pm 0.75, \pm 1.00]$	Jaka

Treba biti oprezan s koeficijentom korelacije kao mjerom kvalitete zato jer je moguće da model s jako lošim sposobnostima predviđanja bude dobro ocijenjen od strane ove mjere kvalitete.

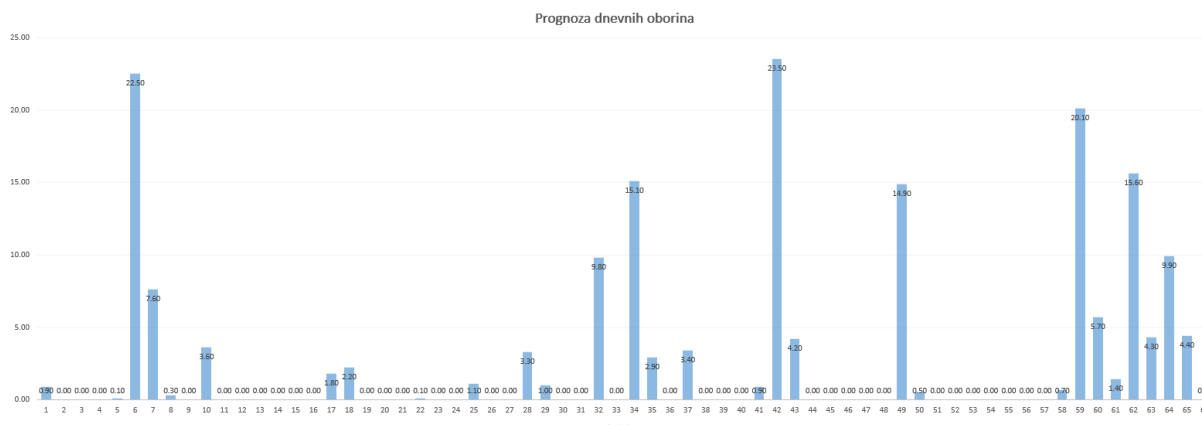
Nepostojanje standardne mjere za ocjenjivanje kvalitete neuronskog modela može uzrokovati nedostatak dosljednosti i objektivnosti prilikom ocjenjivanja modela. Općenito, savjetuje se korištenje barem jedne apsolutne i jedne relativne mjere kvalitete [24].

## 5. TESTOVI, REZULTATI, ANALIZA

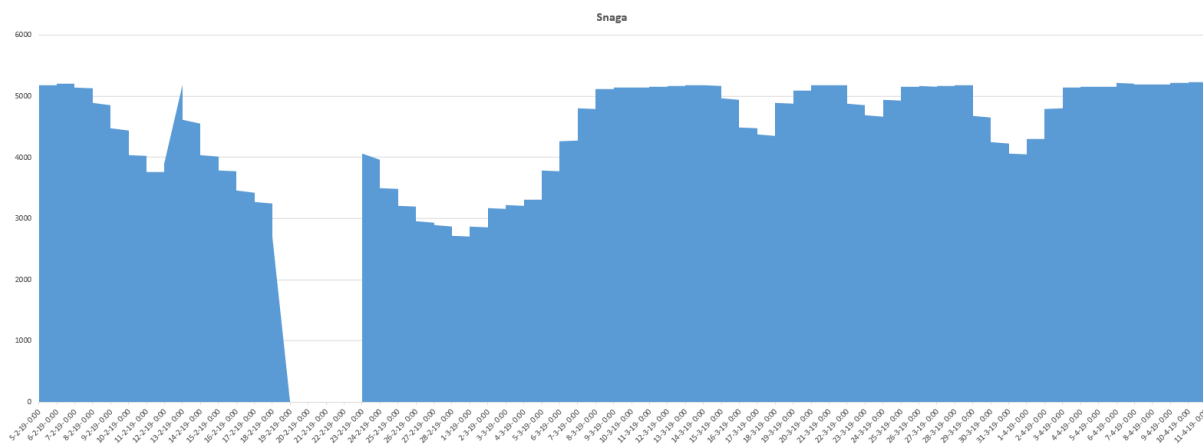
### 5.1. Uvod

Za ovaj rad su bili dostupni podatci o prognozama oborina za mjesto Konjic, Bosna i Hercegovina i podatci o trenutnoj izlaznoj snazi HE Kraljušćica. Podatci su prikupljeni u vremenu od 5. veljače 2019. u 12:00 sati do 11. travnja 2019. godine u 10:00 sati.

Period uzrokovanja je iznosio 1 sat. Na *Slikama 5.1. i 5.2.* su prikazani grafovi prognoza dnevnih oborina u navedenom razdoblju, te podatci o srednjoj izlaznoj snazi HE Kraljušćica u istom razdoblju. U podacima o snazi nalazi se “rupa”, tj. vremenski interval od 19. veljače 2019. u 00:00h do 23. veljače 2019. u 17:00h. u kojemu je iz nepoznata razloga snaga iznosa nula. Snage za 18. veljače 2019. u 23:00h i 23. veljače 2019. u 18:00h ne iznose nula, ali su manje za 39.57% od prosječne vrijednosti srednjih izlaznih snaga tj. 2695.28 kW od 4460.66 kW, odnosno za 74.33% tj. 1145.53 kW od 4460.66 kW. Takva odstupanja ne postoje u ostatku podataka.



*Slika 5.1. Prognoza dnevnih oborina u intervalu od 5.2.2019. do 11.4.2019.*



Slika 5.2. Izlazna prosječna snaga u intervalu od 5.2.2019. do 11.4.2019.

Na samome početku potrebno je naglasiti problem vezan za podatke koji se pojavio prilikom prikupljanja. Način prikupljanja podataka prikazan na *Slici 5.3.* . Na njoj se nalazi isječak podataka u intervalu od 10. travnja 2019. godine u 21:00 sat do 11. travnja 2019. godine u 10:00 sati. Na *Slici 5.3.* se također nalaze podatci o snazi elektrane u nekom od mjerenja i prognoze oborina za sljedeća 24 sata, uz napomenu da su u ovome radu poradi preglednosti prikazane prognoze za sljedećih 14 sati. *Slika 5.3.* se iščitava na sljedeći način: uzmimo kao primjer redak u kojemu se nalazi datum 10. travnja u 21:00h, prognoza oborina za sat vremena unaprijed, tj. za vremenski interval od 21:00 sat do 22:00 sata koji se nalazi u *Stupcu 1* iznosi 0.5 mm. Prognoza za dva sata unaprijed, tj. za sljedeći interval koji se nalazi u *Stupcu 2*, od 22:00h do 23:00h iznosi 0.1 mm. No, ako se pomaknemo u novije vrijeme i pogledamo opet interval od 22:00h do 23:00h, vidjet ćemo da se prognoza promijenila.

Dakle, ako se spustimo jedan red niže gdje se nalazi 10. travnja u 22:00 sata, i tražimo prognozu oborina za vremenski interval od 22:00h do 23:00h, naći ćemo je u *Stupcu 1*. Može se vidjeti da sada prognoza za taj vremenski interval iznosi 0 mm kiše. Što znači da novija prognoza za isti vremenski interval predviđa drugačiju količinu oborina.

Vratimo se u trenutak 10. 4. 2019. u 21:00 sat i pogledajmo *Stupac 4*, odnosno prognozu za interval 00:00h – 01:00h na datum 25. 4. 2019. Prognoza iznosi 0.1 mm kiše. Zatim se spustimo u redak gdje se nalazi datum 25. 4. 2019. u 00:00h i pogledajmo najnoviju prognozu za interval 00:00h – 01:00h koja se sada nalazi u *Stupcu 1*, prognoza iznosi i dalje 0.1 mm, odnosno ako se pogledaju zelenom bojom označena polja, može se zaključiti da se prognoza nije mijenjala.

U poljima crvene boje objašnjeno je zašto je prethodno napisano važno. Naime, tijekom bilježenja podataka dolazilo je do prekida, crvena polja označavaju vremenske intervale kada

prognoze nisu bile bilježene. U ovom isječku prognoze nisu bile bilježene od 11. 4. 2019. u 04:00 sata do 11. 4. 2019. u 09:00 sati. Što znači da su u tom intervalu postojala 144 nepopunjena polja. Polja su popunjena na dva načina, a objašnjena pomoću polja žute boje. U prvom slučaju je iskorištena pretpostavka o istovjetnosti prognoze iz sata u sat, pa su prazna polja popunjena vrijednošću 0.2 mm. Dok je u drugom slučaju bilo očito da se prognoza mijenjala tijekom nebilježenja iste. Ta polja su popunjena proizvoljno odabranom kvazi-linearnom promjenom vrijednosti prognoze. Udio proizvoljnom metodom popunjenih polja iznosi 8.62%, odnosno 3360 od 38976.

Ovo je problem koji je na samome početku narušio vjerodostojnost rezultata koji će biti izneseni u ovome radu, no, nepotpuna vjerodostojnost ne podrazumijeva njihovu beskorisnost.

Datumi uzorkovanja snage	Vremenske oznake uzorkovanja snage	Prosječna snaga	1	2	3	4	5	6	7	8	9	10	11	12	13	14
10-04-19	21:00:00	5219.7681	0.5	0.1	0	0.1	0	0	0	0	0	0	0.1	0.1	0.2	0
10-04-19	22:00:00	5219.2754	0	0	0.1	0	0	0	0	0	0	0	0.1	0.2	0.2	0
10-04-19	23:00:00	5218.4873	0	0.1	0	0	0	0	0	0	0	0.1	0.2	0.2	0	0
11-04-19	0:00:00	5218.9846	0.1	0	0	0	0	0	0	0	0.1	0.2	0.2	0	0	0
11-04-19	1:00:00	5218.6056	0	0	0	0	0	0	0	0.1	0.2	0.2	0	0	0	0
11-04-19	2:00:00	5218.3794	0	0	0	0	0	0	0.1	0.2	0.2	0	0	0	0	0
11-04-19	3:00:00	5218.3713	0	0	0	0	0	0.1	0.2	0.2	0	0	0	0	0	0
11-04-19	4:00:00	5218.3012	0	0	0	0	0.1	0.2	0.2	0	0	0	0	0	0	0
11-04-19	5:00:00	5218.1488	0	0	0	0.1	0.2	0.2	0	0	0	0.2	0	0	0	0
11-04-19	6:00:00	5218.8685	0	0	0.1	0.2	0.2	0	0	0	0.5	0	0	0.2	0	0
11-04-19	7:00:00	5219.3281	0	0.1	0.2	0.2	0	0	0	0.8	0	0	0.4	0	0	0
11-04-19	8:00:00	5218.2885	0.1	0.2	0.2	0	0	0	1.1	0	0	0.6	0	0.1	0	0
11-04-19	9:00:00	5217.1354	0.2	0.2	0	0	0	1.4	0	0	0.8	0	0.2	0.1	0.1	0
11-04-19	10:00:00	5217.1707	0.2	0.1	0	0	1.7	0	0.5	1	0.1	0.3	0.2	0.2	0.1	0.1

Slika 5.3. Isječak sortiranih podataka

Nakon što je objašnjen način prikupljanja podataka, slijedi objašnjenje zašto nam oni uopće trebaju, odnosno što je cilj ovoga diplomskog rada.

Cilj rada je analizirati podatke o vremenskim prognozama i snagama koje proizvodi HE Kraljušćica za kreiranje modela temeljenoga na neuronskim mrežama koji će predviđati potrebe proizvodnje električne energije dvadeset i četiri sata unaprijed (za sljedeći dan u isto vrijeme u intervalu od jednog sata) i na koncu ocjena njegove uspješnosti.

Potreba za ovakvim modelom se javlja zbog činjenice da se male, derivacijske hidroelektrane nalaze na riječnim tokovima čija je dnevna i sezonska fluktuacija protoka vode izrazito velika i model koji bi direktno ili indirektno predviđao promjenu toga protoka bi se mogao iskoristiti za učinkovitije planiranje proizvodnje električne energije.

Nakon prikupljanja, sortiranja i obrade podataka, drugi korak je bio odrediti koje će strukture biti testirane u ovome radu, koji algoritmi, te što će nam biti ulazni a što izlazni podatci.

Testirano je sljedeće:

- NARX i NAR strukture
- Levenberg-Marquardt i Bayesian algoritmi
- Osam skupova ulaznih i izlaznih podataka

Strukture i algoritmi su objašnjeni u *Poglavlju 4.5.*, a sada slijedi objašnjenje podjele ulaznih i izlaznih podataka na osam skupova.

Na *Slici 5.4.* je prikazana shema NARX modela, kao što se vidi, NARX modeli kao ulazne varijable mogu primati:

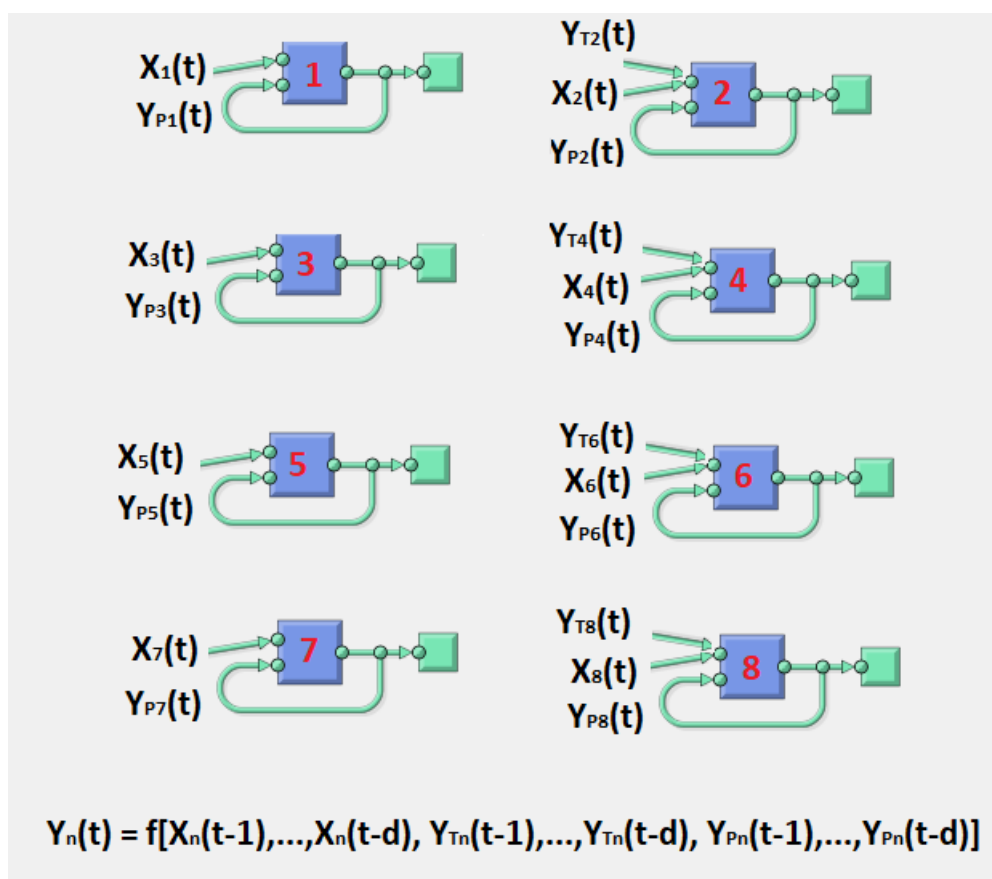
- $X_O(t)$ : Podatci o vremenskim prognozama, gdje “O” označava “oborine”.
- $Y_T(t)$ : Trenutni podatci o snazi, gdje “T” označava “trenutno”.
- $Y_P(t)$ : Podatci o snazi iz prošlosti, gdje “P” označava “prošlost”.

Podatci o snazi su iz prošlosti  $Y_P(t)$  uvijek su prisutni, što je očito iz pogleda na shemu NARX strukture, *Slika 4.1.*

Osim podataka o snazi iz prošlosti, moguće je svojevolumno dodavati druge ulazne tipove podataka. U ovome radu su testirana dva načina:

- u prvom načinu su pored  $Y_P(t)$ , na ulaz svojevolumno dovođeni podatci o prognozama oborina  $X_O(t)$ ,
- u drugom načinu su pored  $Y_P$ , na ulaz svojevolumno dovođeni podatci o prognozama oborina  $X_O(t)$  i podatci o trenutačnim snagama  $Y_T(t)$ .

Cilj takve podjele je provjeriti je li dodavanje podataka o trenutačnoj snazi pomaže modelu u predviđanjima srednje izlance snage za 24 sata unaprijed. Ta dva načina su primijenjena na četiri različita skupa podataka, što u konačnici daje osam različitih skupova podataka za testiranje. Shematski su prikazani na *Slici 5.4.*, gdje brojevi crvene boje označavaju redni broj skupa “n”.



Slika 5.4. Načini testiranja NARX strukture

A na Slici 5.5. su prikazani sortirani podatci. U posljednjem stupcu (E) se nalaze prognoze oborina za sljedećih sat vremena; to je ranije spomenuta varijabla  $X_O(t)$ . Prosječna snaga je ranije spomenuta varijabla  $Y_T(t)$ . Ako se promatra red za 5. 2. 2019. u 12:00 sati, stupac (E) pokazuje vremensku prognozu za sat vremena unaprijed, tj. za vremenski interval od 12:00h do 13:00h. Ista logika vrijedi za sve ostale retke. Od dvadeset i četiri dostupna stupca prognoza, prvi je izabran zbog toga što se u njemu nalaze najnoviji podatci o prognozama koji su zbog te činjenice i najtočniji.

Prvi način testiranja mreže obavljen je na sljedeći način:

Zadatak mreže je na temelju prognoze o oborinama, varijabla  $X_O(t)$ , za 5. 2. 2019. u 12:00h predvidjeti snagu koju elektrana treba proizvesti, varijabla  $Y_T(t)$ , za 6. 2. 2019. u 12:00h. Snaga u potonjem trenutku se naziva „target“ snaga, a veza između ta dva podatka je označena žutom bojom. Uz napomenu da ne treba miješati ulaznu varijablu  $Y_T(t)$  sa „target“ snagom iako se nalaze u istom stupcu! U naknadnom postupku sortiranja podataka, koji u ovome radu nije prikazan, te dvije skupine podataka su potpuno razdvojene, ovdje su prikazane u istom stupcu u svrhu objašnjenja načina povezivanja ulaznih i „target“ podataka. Ljubičastom bojom je označena veza između prognoze za 5. 2. 2019. u 13:00h i „target“ snage za 6. 2. 2019. u 13:00h,

svijetlo plavom bojom je označena veza između prognoze i „*target*“ snage za odgovarajući trenutak u budućnosti. Redovi 1, 2, 3 i 25, 26, 27 su bojama označeni radi lakšeg shvaćanja veze između podataka, ista logika povezivanja podataka vrijedi za sve ostale podatke.

Drugi način testiranja mreže obavljen je na sljedeći način:

U odnosu na prvi, ovaj način treniranja mreže razlikuje se po tome što na ulaz modela ne dovodimo samo varijablu  $X_O(t)$ , nego i trenutne snage  $Y_T(t)$ . Npr., na temelju podatka o prognozi oborina za 5. veljače 2019. u 12:00h i podatka o snazi za isti interval, model treba predvidjeti „*target*“ snagu koju elektrana treba proizvesti na 6. veljače 2019. u 12:00h. Ista logika vrijedi za ostatak podataka.

A	B	C	D	E
Novi redoslijed podataka	Datumi uzorkovanja snage	Vremenske oznake uzorkovanja snage	Prosječna snaga	[0-1]
			$Y_T(t)$	$X$
1	05-02-19	12:00:00	5184.26	0
2	05-02-19	13:00:00	5183.7743	0
3	05-02-19	14:00:00	5184.0143	0
4	05-02-19	15:00:00	5182.0067	0
5	05-02-19	16:00:00	5177.7166	0
6	05-02-19	17:00:00	5178.6046	0.2
7	05-02-19	18:00:00	5178.5329	0.2
8	05-02-19	19:00:00	5179.1927	0.2
9	05-02-19	20:00:00	5177.8382	0.1
10	05-02-19	21:00:00	5173.0233	0
11	05-02-19	22:00:00	5171.1374	0
12	05-02-19	23:00:00	5170.3579	0
13	06-02-19	0:00:00	5172.1599	0
14	06-02-19	1:00:00	5181.886	0
15	06-02-19	2:00:00	5182.4406	0
16	06-02-19	3:00:00	5182.8084	0
17	06-02-19	4:00:00	5184.4824	0
18	06-02-19	5:00:00	5184.8798	0.1
19	06-02-19	6:00:00	5184.0393	0.1
20	06-02-19	7:00:00	5183.9226	0
21	06-02-19	8:00:00	3899.2621	0
22	06-02-19	9:00:00	5057.3076	0
23	06-02-19	10:00:00	5206.7328	0
24	06-02-19	11:00:00	5205.0044	0
25	06-02-19	12:00:00	5203.2278	0
26	06-02-19	13:00:00	5201.7813	0
27	06-02-19	14:00:00	5200.7646	0
28	06-02-19	15:00:00	5199.5161	0
29	06-02-19	16:00:00	5197.859	0
30	06-02-19	17:00:00	5203.5585	0

Slika 5.5. Isječak ulaznih i „*target*“ podataka

$X_{On}(t)$  – Podatci o prognozama oborina za skup pod rednim brojem n.

$Y_{Tn}(t)$  – Podatci o trenutnim snagama za skup pod rednim brojem n.

$Y_{Pn}(t)$  – Podatci o snagama iz prošlosti za skup pod rednim brojem n.



Prilikom sortiranja ulaznih skupova podataka, prvi i drugi skup podataka nisu filtrirani, pa je varijabla  $X_{O1}(t)$  zapravo isto što i  $X_{O2}(t)$ , no zasebno su označene radi logičke dosljednosti u numeriranju, u preostalim skupovima zbog načina filtriranja podataka, ovo ne vrijedi.

U trećem i četvrtom skup podataka filtrirani su svi podatci o „*target*“ snagama koji imaju vrijednost nula, te svi  $X_O(t)$  i  $Y_T(t)$  podatci koji su povezani sa „*target*“ snagama iznosa nula.

S obzirom da na intervalu gdje su podatci o snagama nula, promjene ne nastupaju naglo nego postpuno, kao što je navedeno na početku ovoga poglavlja; u petom i šestom skup podataka izbačeni su i takvi „*targetni*“ podatci i za njih vezani  $X_O(t)$  i  $Y_T(t)$  podatci. Vrijednosti tih podataka u *Skupovima 3, 4, 5 i 6* su izbačene jer su više uvjetovane djelovanjem čovjeka nego vremenskom prognozom. Pretpostavka koja se provjeravala u testiranjima jest da takav utjecaj čovjeka negativno utječe na sposobnost predviđanja modela.

*Skup 7 i Skup 8* su formirani tako da su u obzir uzeti samo  $X_O(t)$  i  $Y_T(t)$  podatci nakon pojave intervala u kojemu je uključen faktor ljudskog utjecaja.

U NAR modelu postoji jedan izuzetak, pa imamo sedam različitih skupova za treniranje. Naime, u NAR modelu ulazni podatci su samo izlazni podatci iz prošlosti  $Y_{Ph}(t)$ , a kako *Skup 1 i Skup 2* imaju isti broj izlaznih podataka i iste izlazne podatke, ta dva skupa postaju jedan skup i u konačnici dobivamo sedam skupova za testiranje.

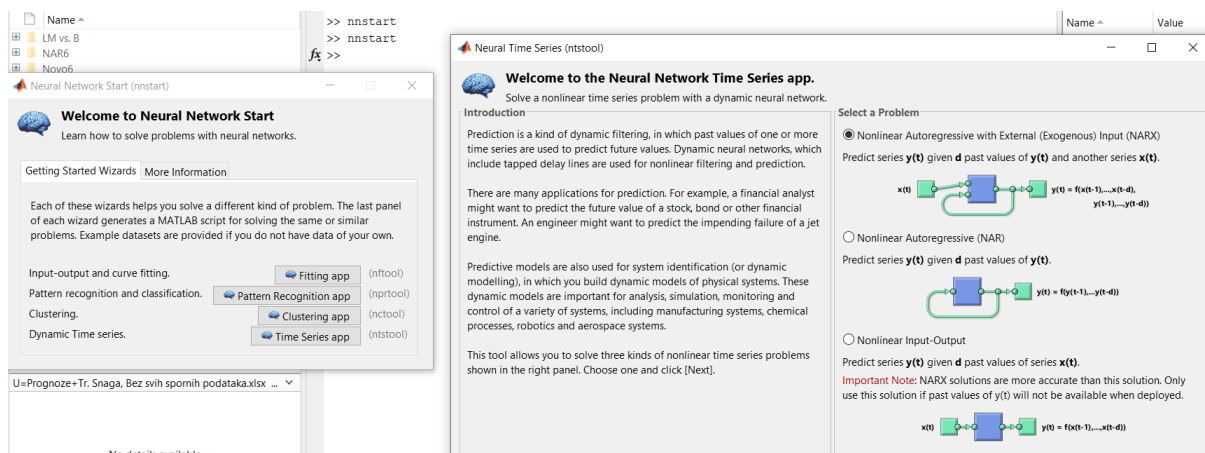
Postavlja se pitanje, zašto sedam a ne četiri ako sada ne primjenjujemo dva načina dovođenja ulaznih podataka? Zbog ranije spomenutog postupka izbacivanja određenih podataka, svaki skup ima različit broj podataka. Pa su to onda i dalje različiti skupovi koje je potrebno zasebno testirati. U *Tablici 5.1.* su navedeni svi skupovi podataka i njihova količina po pojedinom skup.

*Tablica 5.1. Broj podataka po pojedinom skupu*

n	Na ulazu su $X_O(t)$ , $X_{Pn}(t)$	Broj podataka	n	Na ulazu su $X_O(t)$ , $X_{Tn}(t)$ , $X_{Pn}(t)$	Broj podataka
1	Svi podatci su uključeni	1535	2	Svi podatci su uključeni	1535
3	Snage iznosa nula su izbačene i pripadne prognoze	1421	4	Snage iznosa nula su izbačene i pripadne prognoze	1397
5	Svi sporni podatci su izbačeni i pripadne snage	1420	6	Svi sporni podatci su izbačeni i pripadne snage	1395
7	Korišteni su samo podatci nakon pojave snaga iznosa nula	1120	8	Korišteni su samo podatci nakon pojave snaga iznosa nula	1096

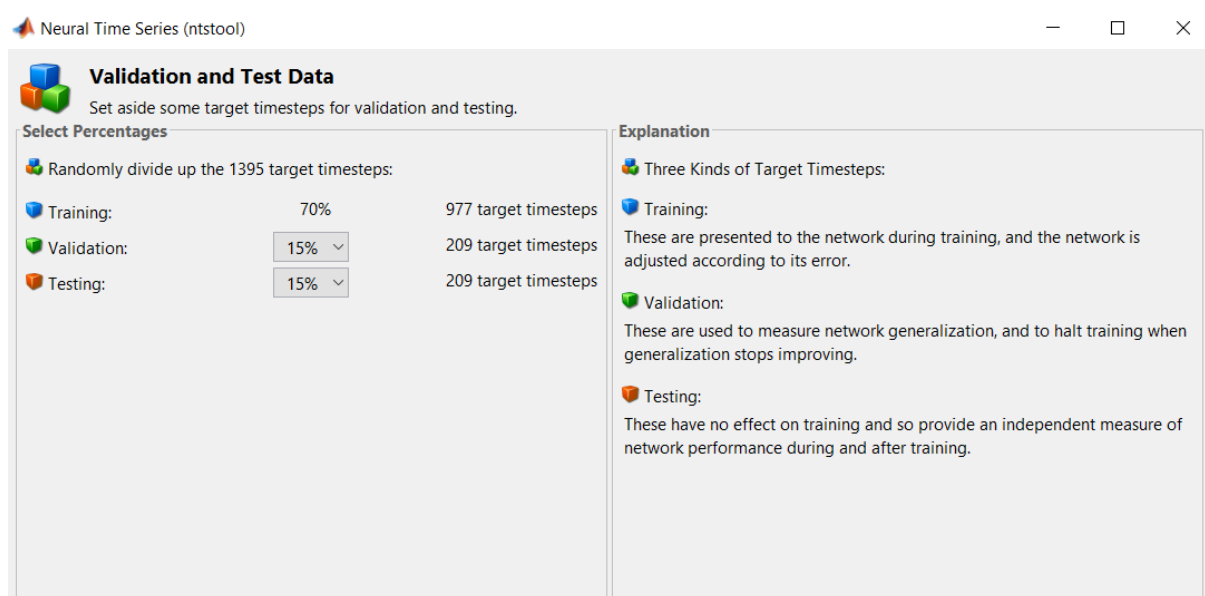
## 5.2. Programski paket MATLAB

Programski paket MATLAB ima ugrađen alat za treniranje neuronskih mreža, pokreće se naredbom „nnstart“, zatim se biraju željene metode, strukture i postavke za treniranje mreže.



Slika 5.6. Opcije za treniranje u programskom paketu MATLAB

Metode i strukture koje su korištene u ovome radu su ranije navedene. Kad je riječ o postavkama, nakon odabira ulaznih podataka, moguće je odabirati različite udjele podataka za treniranje, validaciju i testiranje. U cijelom ovome radu su korištene početne postavke gdje je 70% podataka korišteno za trening, 15% za validaciju i 15% za testiranje.



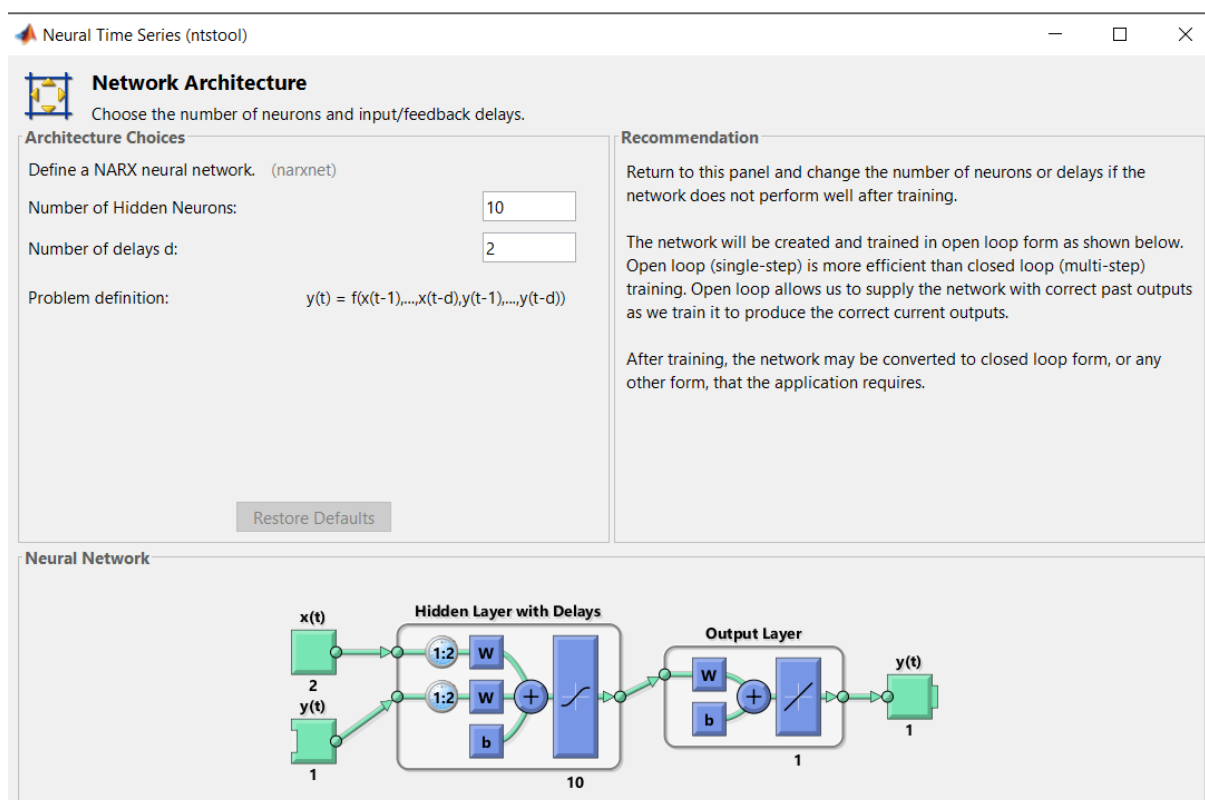
Slika 5.7. Distribucija podataka

**Trening** – dio u kojem UNM mreža preuzima ulazne parametre i spaja ih s “*target*” parametrima, pokušavajući zadati odgovarajuće težinske faktore svakom ulaznom parametru [36].

**Validacija** – dio u kojem mreža vrši korekciju težinskih faktora. Validacijski dio također se može smatrati dijelom treniranja mreže, no on djelomično i priprema mrežu za posljednji, testni dio [36].

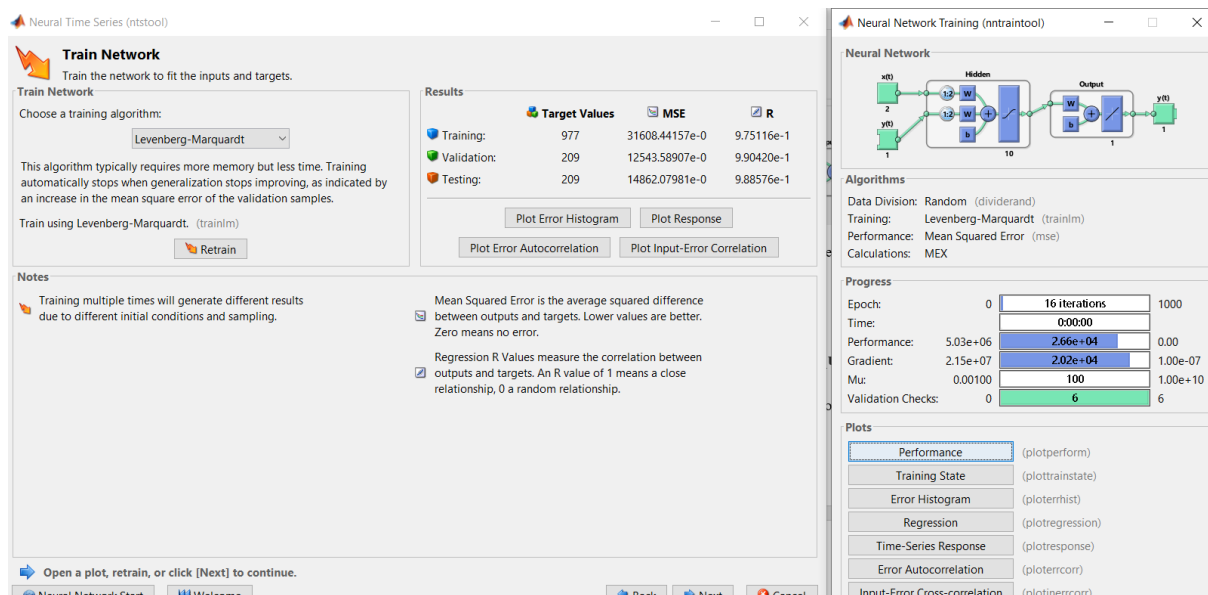
**Test** – dio u kojem mreža bez dostupnih “*target*” parametara pokušava predvidjeti vrijednosti istih. Točnost rezultata testnog dijela odražava preciznost i uspješnost neuronske mreže [36].

Sljedeći korak jest biranje broja neurona skrivenoga sloja, i broja broja „*delay*“ vrijednosti. „*Delay*“ vrijednost označava koliko podataka iz prošlosti uzimamo prilikom testiranja mreže.



Slika 5.8. Izbor karakteristika mreže

Zatim slijedi proces treniranja mreže.



Slika 5.9. Prikaz rezultata nakon procesa treniranja

U ovom prozoru možemo birati željeni algoritam, pokretati treninge mreže, pregledati sedam grafova koji svaki na svoj način opisuju treniranu mrežu i vidjeti različita numerička vrednovanja mreže. U ovome radu je posebna pozornost usmjerena na MSE i R vrijednost „Testing“ skupine i „Regression“ te „Time-Series Response“ grafovima.

Nakon svakoga „retraina“ rezultati su drugačiji i mogu drastično oscilirati. U ovom radu vršeno je deset „retraina“ za svaku kombinaciju neurona i „delay-a“, a zašto baš deset, objašnjeno je u [37]. U navedenom radu je pokazano deset „retraina“ koji daju dovoljno visoku vjerojatnost da smo pronašli globalni minimum. Veći broj „retrain-a“, naravno, povećava tu vjerojatnost ali više „retrain-a“ znači više utrošenoga vremena.

### 5.3. Usporedba performansi Levenberg-Marquart i Bayesian algoritma

Prilikom usporedbe Levenberg-Marquardt i Bayesian algoritma, korištena je mreža s 50 neurona i „delay“ vrijednostima od 1 do 5 te NARX struktura. Poželjno je testirati mrežu na većem rasponu broja neurona, no, zbog izrazite sporosti procesa treniranja Bayesian algoritma, odabran je broj neurona za kojeg je trajanje procesa treniranja razumno dugo.

Prilikom testiranja je utvrđeno da je Pearsonov koeficijent R za Bayesian algoritam u 75% slučajeva iznad 0.9, odnosno u 30 od 40 slučajeva, dok je za Levenberg-Marquardt Pearsonov koeficijent R iznad vrijednosti 0.9 u 97.75% slučajeva, odnosno u 39 od 40 slučajeva.

Najmanji Pearsonov koeficijent R za Bayesian algoritam iznosi 0.705 a najveći iznosi 0.99983, najmanji Pearsonov koeficijent R za LM algoritam iznosi 0.526 a najveći iznosi 0.99927.

Prosječan Pearsonov koeficijent R za Bayesian algoritam iznosi 0.919, a prosječan Pearsonov koeficijent R za LM algoritam iznosi 0.977.

U 77.5% slučajeva, LM algoritam ima manju MSE vrijednost od Bayesian algoritma, odnosno u 31 od 40 usporedbi.

Maksimalna RMSE pogreška Bayesian algoritma iznosi 58697.19 za skup sedam i broj „*delay-a*“, iznosa pet.

Najveća RMSE vrijednost LM algoritma iznosi 257.94 za *Skup 3* iznosa „*delay-a*“ pet.

U konačnici, za nastavak rada je odabran LM algoritam zbog toga što je Bayesian algoritam u prosjeku nepouzdaniji i češće daje izrazito loše rezultate, a i računalno je zahtjevan.

Potrebno je napomenuti da Bayesian algoritam ima svoje prednosti; u *Poglavlju 4.3.* je već spomenuto da je Bayesian algoritam nadogradnja LM algoritma, optimira broj parametara po više funkcije cilja, iako je Bayesian algoritam u prosjeku nepouzdaniji i češće daje izrazito loše rezultate, također daje najmanju RMSE vrijednost. Ta vrijednost iznosi 20.47, za *Skup 8* i broj „*delay-a*“ iznosa 1. Najmanja RMSE vrijednost za LM algoritam iznosi 73.157.

## 5.4. Rezultati NARX strukture za LM algoritam

NARX struktura je testirana za 10, 50, 100 i 500 neurona, sa rasponom „*delay-a*“ od 1 do 5.

Vrijednost R je najčešće približno 1, što govori da postoji jaka veza između ulaznih i izlaznih podataka. Za veće RMSE vrijednosti primjećuje se pad korelacije. Primjer rezultata podataka je pokazan u *Tablici 5.2.*, u tablici se nalaze rezultati za *Skup 1.* Najmanja RMSE vrijednost u skupu je označena podebljanim brojem.

Tablica 5.2. RMSE vrijednosti za Skup 1 – NARX

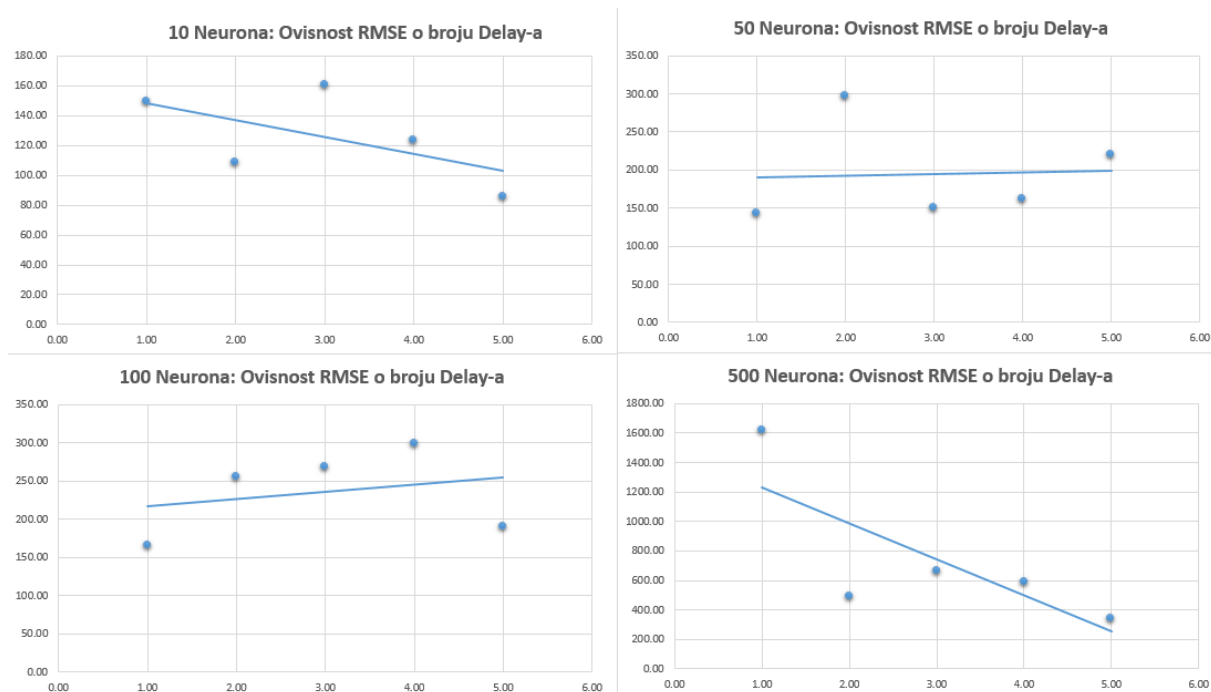
Broj neurona	Broj „delay-a“	RMSE	R
10	1	149.24	0.99
	2	108.93	1.00
	3	160.93	0.99
	4	123.53	1.00
	5	<b>85.80</b>	1.00
50	1	142.48	1.00
	2	297.48	0.98
	3	150.24	0.99
	4	162.55	0.99
	5	220.43	0.99
100	1	165.95	0.99
	2	255.32	0.99
	3	268.88	0.99
	4	299.45	0.98
	5	189.59	0.99
500	1	1617.56	0.60
	2	489.23	0.95
	3	666.85	0.91
	4	590.62	0.92
	5	343.14	0.97

Na *Slici 5.10.* prikazane su ovisnosti RMSE vrijednosti o broju „delay-a“ i ovisnosti RMSE vrijednosti o broju neurona za *Skup 1.*

Kod ovisnosti o RMSE vrijednosti o broju „delay-a“ za *Skup 1*, u dva navrata linearna regresija ima pozitivan koeficijent a u dva navrata negativan koeficijent. Općenito, ako promatramo sve skupove, pojava uzlaznih i silaznih regresija kod ovisnosti RMSE vrijednosti o broju „delay-a“, je nema jednoznačan logički obrazac ponašanja, što se može vidjeti u *s Tablici 5.3.* . Od trideset i dvije usporedbe, u dvadeset njih je regresija bila uzlazna (62.5%) a u dvanaest slučajeva (37.5%) regresija je imala silaznu vrijednost.

Tablica 5.3. Raspored pojavnosti regresija za ovisnost RMSE vrijednosti o broju „delay-a“ - NARX

Redni broj skupa	Broj uzlaznih regresija	Broj neurona za uzlazne regresije	Broj silaznih regresija	Broj neurona za silazne regresije
1	2	50, 100	2	10, 500
2	2	100, 500	2	10, 50
3	3	10, 50, 100	1	500
4	1	10	3	50, 100, 500
5	3	10, 50, 100	1	500
6	3	10, 100, 500	1	50
7	2	10, 100	2	50, 500
8	4	10, 50, 100, 500	0	/
<b>Ukupno:</b>	<b>20</b>	<b>6x10, 4x50, 7x100, 3x500</b>	<b>12</b>	<b>2x10, 4x50, 1x100, 5x500</b>



Slika 5.10. Ovisnost RMSE o broju „delay-a“ za svaki od broja treniranih neurona - NARX



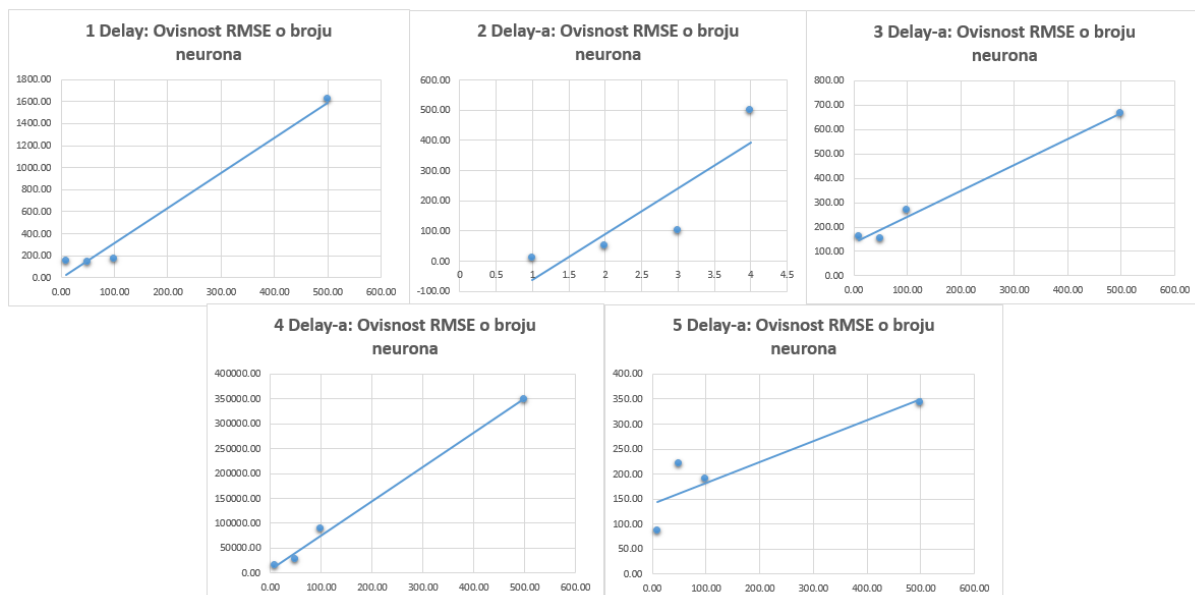
Na *Slici 5.11* je prikazana ovisnost RMSE o broju neurona za *Skup 1*, u svih pet usporedbi regresija je uzlazna. I ne samo u ovome skupu, nego u svim ostalim skupovima je svaka regresija (40 njih) uzlazna, na osnovu čega se može zaključiti da povećanjem broja neurona RMSE raste, tj. povećanje broja neurona loše utječe na performanse sustava. To se događa zbog toga što povećanjem broja neurona raste kompleksnost mreže.

To možemo zaključiti i ako analiziramo na kojoj poziciji se u svakom skupu javlja najmanja pogreška. Najmanja pogreška od svih skupova je ponovno označena podebljanim brojem.

*Tablica 5.4. Najmanje RMSE vrijednosti za svaki od skupova - NARX*

Redni broj skupa	Broj neruona za najmanji RMSE	Broj „delay-a“ za najmanji RMSE	Vrijednost najmanje RMSE
1	10	5	85.80
2	10	4	109.61
3	10	2	47.49
4	10	1	93.24
5	50	1	63.99
6	10	1	68.76
7	10	3	27.05
8	10	1	<b>25.75</b>

Kao što je iz *Tablice 5.4.* vidljivo, u 7 od 8 primjera najmanja pogreška se javila na mreži od 10 neurona. Iako nije primijećen nedvosmislen uzorak po kojemu se može zaključiti kako broj „delay-a“ utječe na RMSE, u *Tablici 5.4.* se može vidjeti da se u 50% slučajeva, tj. u 4 od 8 slučajeva, najmanji RMSE javlja za „delay“ iznosa 1, što implicira da bi taj iznos „delay-a“ mogao biti najbolji mogući izbor.



Slika 5.11. Ovisnost RMSE o broju neurona za svaki od „delay-a“ – NARX

Na temelju Tablice 5.5. analizira se odnos između rezultata modela koji kao ulazne podatke imaju  $X_{On}(t)$ ,  $Y_{Pn}(t)$  i rezultata modela koji kao ulazne podatke imaju  $X_{On}(t)$ ,  $Y_{Tn}(t)$ ,  $Y_{Pn}(t)$ . Odnosno, uspoređuje se Skup 1 sa Skupom 2, Skup 3 sa Skupom 4, Skup 5 sa Skupom 6 i Skup 7 sa Skupom 8. Preciznije, uspoređuju se prosječne RMSE vrijednosti za pojedinu skupinu neurona.

Npr. prosječni RMSE za 10 neurona iz Skupa 1 se uspoređuje sa prosječnim RMSE za 10 neurona iz Skupa 2, i tako dalje.

Te se uspoređuje prosjek svih RMSE vrijednosti iz Skupa 1 sa prosjekom svih RMSE vrijednosti iz Skupa 2, i tako dalje.

Skup 1 i Skup 2:

- U tri od četiri slučaja prosječni RMSE za svih pet „delay-a“ po grupi neurona neurona je manji za Skup 2.
- Prosjek svih RMSE vrijednosti iz skupa je manji za Skup 2.

Skup 3 i skup 4:

- Prosječni RMSE za svih pet „delay-a“ po grupi neurona je u dva slučaja manji za Skup 3, a u dva slučaja je manji za Skup 4.
- Prosjek svih RMSE vrijednosti je manji za Skup 4.

*Skup 5 i 6:*

- Prosječni RMSE za svih pet „delay-a“ po grupi neurona je u dva slučaja manji za „Skup 5“, u dva slučaja je manji za „Skup 6“.
- Prosjek svih RMSE vrijednosti je manji za „Skup 5“.

*Skup 7 i Skup 8:*

- U tri od četiri slučaja prosječni RMSE za svih pet „delay-a“ po grupi neurona je manji za Skup 8.
- Prosjek svih RMSE vrijednosti iz skupa je manji za Skup 8.

Ukupno, u 10 od 16 slučajeva, tj. u 62.5% slučajeva, prosječni RMSE za svih pet „delay-a“ po grupi neurona je manji za modele koji na ulazu imaju varijable  $X_{On}(t)$ ,  $Y_{Tn}(t)$ ,  $Y_{Pn}(t)$ .

Prosijek svih RMSE vrijednosti u skupu je u 3 od 4 slučaja, tj. u 75% slučajeva, manji za skupove koji na ulazu imaju varijable  $X_{On}(t)$ ,  $Y_{Tn}(t)$ ,  $Y_{Pn}(t)$ .

Najmanji prosjek svih RMSE vrijednosti se nalazi u Skupu 8, iznosi 83.82.

Prosječni RMSE za skupove kojima su ulazne varijable  $X_{On}(t)$ ,  $Y_{Tn}(t)$ ,  $Y_{Pn}(t)$ , iznosi 186.525 i manji je nego nego prosječni RMSE za skupove kojima su ulazne varijable  $X_{On}(t)$ ,  $Y_{Pn}(t)$  i iznosi 225.34 .

Na temelju analize rezultata *Tablice 5.5.* i *Tablice 5.6.* može se zaključiti da dodavanje varijable  $Y_{Tn}(t)$  na ulaz modela, pozitivno utječe na performanse. Gdje je RBS – Redni brojevi skupova

Na temelju *Tablice 5.7.* vrši se nastavak ove analize, npr., uspoređivana je RMSE vrijednost iz Skupa 1, za 10 neurona i 1 „delay“ koja je iznosila 149.24 , sa RMSE vrijednošću iz Skupa 2 za 10 neurona i 1 „delay“ koja je iznosila 136.78. Kao što se vidi, vrijednost potonje je manja i Skupu 2 je upisana “pobjeda”, Ukupno, Skupovi 1, 3, 5 i 7 imaju 39 pobjeda a Skupovi 2, 4, 6 i 8 imaju 41 pobjedu. Neznatna prednost je opet na strani modela koji na ulazu imaju dodan parametar  $Y_{Tn}(t)$ . Prilikom formiranja *Tablice 5.7.* primijećen je obrazac u rasporedu pobjeda, pa je formirana *Tablica 5.8.* iz koje se može iščitati da za manji broj neurona tj. 10 i 50 bolje rezultate daju modeli za Skupove 1, 3, 5 i 7 a za veći broj neurona tj. 100 i 500 bolje rezultate daju modeli za Skupove 2, 4, 6 i 8.

Na temelju *Tablice 5.8.* se može zaključiti da iako dodavanje parametra  $Y_{Tn}(t)$  na ulaz pozitivno utječe na performanse sustava, ne može se jednoznačno zaključiti da će pozitivno utjecati uvijek i u svakom slučaju.

Tablica 5.5. Detaljnija tablica RMSE vrijednosti po skupovima - NARX

RBS kojima su ulazne varijable $X_{On}(t), Y_{Pn}(t)$	Broj neurona	Prosjek RMSE za svih pet „delay-a“	RBS kojima su ulazne varijable $X_{On}(t), Y_{Tn}(t), Y_{Pn}(t)$	Broj neurona	Prosjek RMSE za svih pet „delay-a“
1	10	<b>125.69</b>	2	10	141.95
	50	194.64		50	<b>150.78</b>
	100	235.84		100	<b>228.59</b>
	500	741.48		500	<b>417.46</b>
	Prosjek svih RMSE iz skupa	324.41		Prosjek svih RMSE iz skupa	<b>234.69</b>
3	10	<b>93.08</b>	4	10	112.11
	50	<b>161.70</b>		50	177.83
	100	224.56		100	<b>204.18</b>
	500	620.03		500	<b>382.33</b>
	Prosjek svih RMSE iz skupa	274.84		Prosjek svih RMSE iz skupa	<b>219.11</b>
5	10	90.26	6	10	<b>90.00</b>
	50	<b>102.00</b>		50	158.36
	100	<b>181.21</b>		100	202.93
	500	439.77		500	<b>382.61</b>
	Prosjek svih RMSE iz skupa	<b>203.31</b>		Prosjek svih RMSE iz skupa	208.48
7	10	<b>32.82</b>	8	10	37.96
	50	79.24		50	<b>38.94</b>
	100	85.96		100	<b>73.85</b>
	500	197.18		500	<b>184.52</b>
	Prosjek svih RMSE iz skupa	98.80		Prosjek svih RMSE iz skupa	<u><b>83.82</b></u>

*Tablica 5.6. Usporedba prosječnih RMSE vrijednosti*

Prosječni RMSE za skupove kojima su ulazne varijable $X_{On}(t)$ , $Y_{Pn}(t)$	Prosječni RMSE za skupove kojima su ulazne varijable $X_{On}(t)$ , $Y_{Tn}(t)$ , $Y_{Pn}(t)$
225.34	186.525

*Tablica 5.7. Usporedba RMSE vrijednosti za svako pojedino mjerenje*

Redni brojevi skupova kojima su ulazne varijable $X_{On}(t)$ , $Y_{Pn}(t)$	Broj pobjeda	Redni brojevi skupova kojima su ulazne varijable $X_{On}(t)$ , $Y_{Tn}(t)$ , $Y_{Pn}(t)$	Broj pobjeda
1	9	2	11
3	10	4	10
5	13	6	7
7	7	8	13
<b>Ukupno:</b>	<b>39</b>		<b>41</b>

Tablica 5.8. Usporedba RMSE vrijednosti za svako pojedino mjerenje grupirano po neuronima

Redni brojevi skupova kojima su ulazne varijable $X_{On}(t)$ , $Y_{Pn}(t)$	Skup neurona	Broj pobjeda	Redni brojevi skupova kojima su ulazne varijable $X_{On}(t)$ , $Y_{Tn}(t)$ , $Y_{Pn}(t)$	Skup neurona	Broj pobjeda
1	10 i 50	6	2	10 i 50	4
	100 i 500	3		100 i 500	7
3	10 i 50	8	4	10 i 50	2
	100 i 500	2		100 i 500	8
5	10 i 50	7	6	10 i 50	3
	100 i 500	6		100 i 500	4
7	10 i 50	2	8	10 i 50	8
	100 i 500	5		100 i 500	5
	<b>10 i 50 ukupno</b>	<b>23</b>		<b>10 i 50 ukupno</b>	<b>17</b>
	<b>100 i 500 ukupno</b>	<b>16</b>		<b>100 i 500 ukupno</b>	<b>24</b>

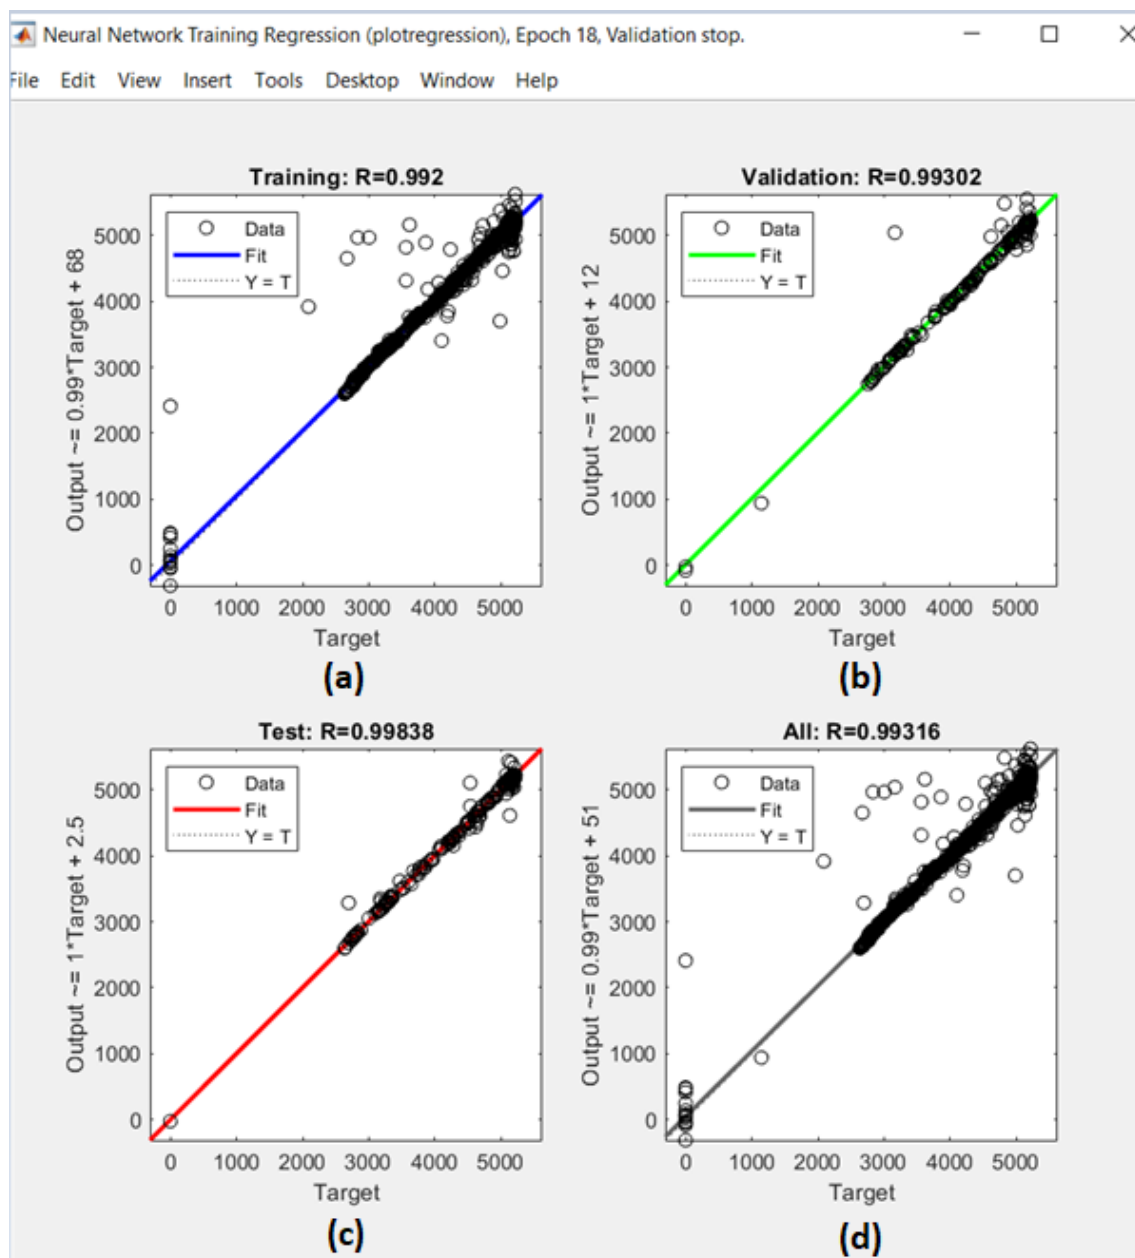
Ako se pogleda Tablica 5.4. i vrijednosti najmanjih RMSE vrijednosti, na prvu bi se dalo zaključiti da je najbolja mreža ona s najmanjom vrijednosti RMSE. To je mreža iz Skupa 8, sa deset neurona i jednim „delay-om“, RMSE vrijednosti 25.75 . Općenito, primjećuje se da Skup 7 i Skup 8 imaju osjetno manje RMSE vrijednosti. No, zaključci o tome koji model je najbolji se ne mogu donositi isključivo na temelju numeričkih, statističkih ocjena. Ti zaključci uvelike ovise i o zahtjevima koji se postavljaju pred model.

Jedan od zahtjeva koji se nameće jest sposobnost obrade kompleksnih podataka. Podatci Skupa 7 i Skupa 8 su najmanje kompleksni; prisjetimo se, u tim skupovima se nalaze samo oni podatci koji u potpunosti eliminiraju efekte utjecaja čovjeka, tj. efekte pada srednje snage elektrane na 0 MW.

Najkompleksniji podatci su oni iz *Skupa 1* i *Skupa 2*. Modeli koji obrađuju taj skup podataka moraju predvidjeti izravni utjecaj čovjeka na rad elektrane, sposobnost predviđanja takvih utjecaja je poželjna čak i ako takav model ne daje najmanju RMSE vrijednost. Zbog toga će u nastavku biti analizirani grafički prikazi odziva za model *Skupa 1* koji obrađuje najkompleksniji skup podataka i model *Skupa 8* koji ima najmanju RMSE pogrešku.

*Skup 1* je ponovno “retrain-an” deset puta (*Slika 5.8.* i *Slika 5.9.*) pod istim uvjetima; najmanji dobiveni RMSE je iznosio 83.03 a Pearsonov koeficijent je iznosa 0.99. Također je i *Skup 8* ponovno “retrain-an” deset puta pod istim uvjetima, najmanji dobiveni RMSE je iznosio 25.75 a Pearsonov koeficijent je iznosa 0.99. Najinteresantniji skupovi na kraju su ponovno “retrain-ani” kako bi se zabilježile njihove grafičke karakteristike, bilježenje grafičkih karakteristika svih testova bi bilo previše vremeski zahtjevno.

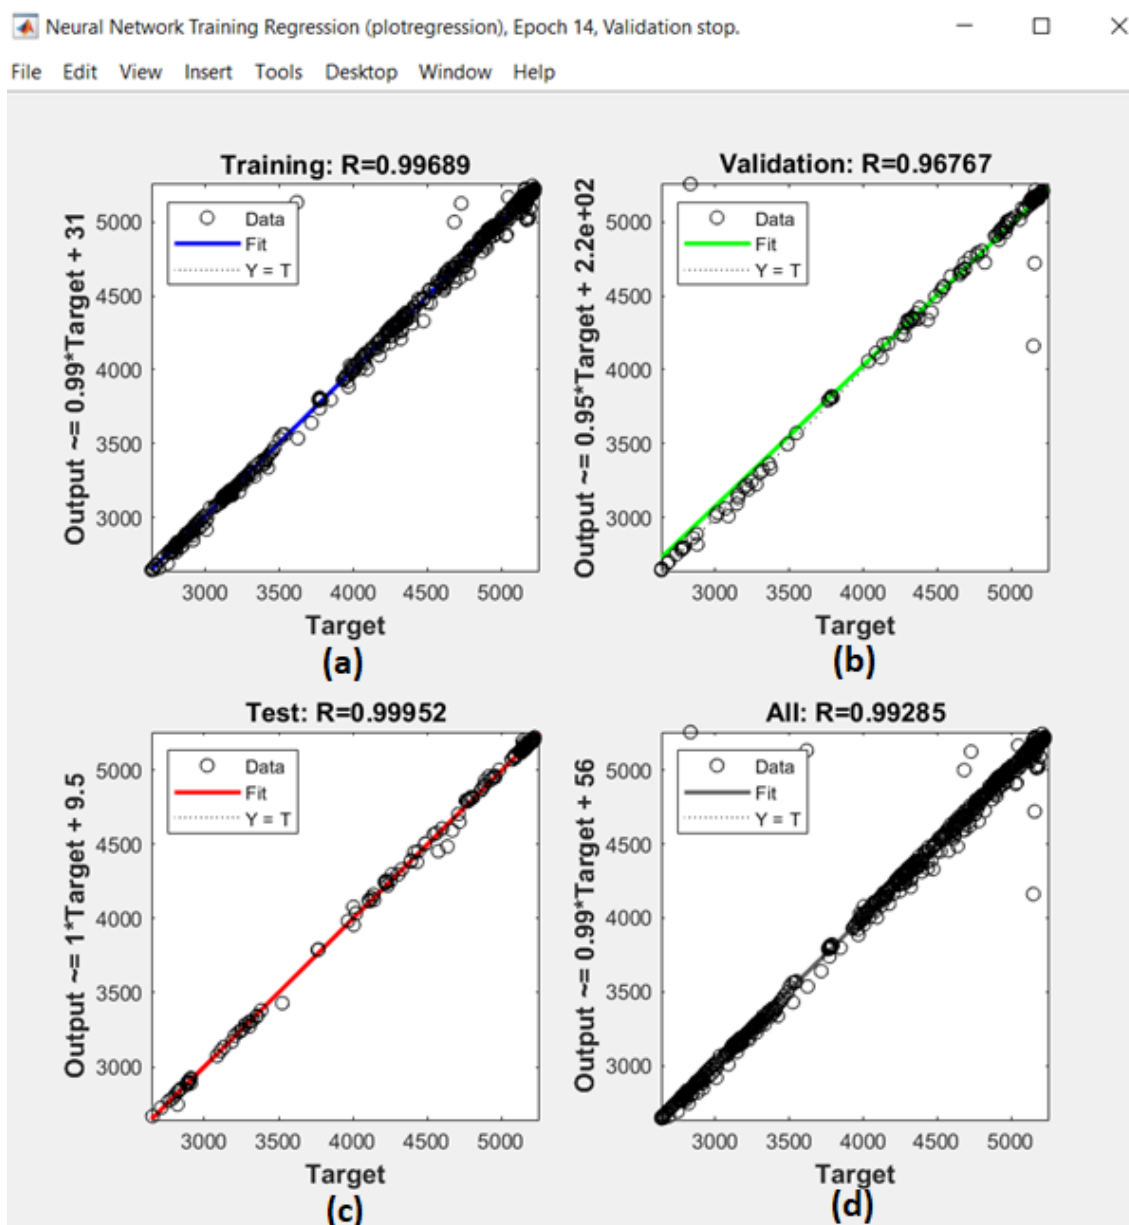
*Slika 5.12.* i *Slika 5.13.* grafički prikazuju regresije za rezultate *Skupa 1* i *Skupa 8*. Iako su vrijednosti Pearsonovog koeficijenta  $R$  za testnu skupinu podataka za oba primjera približno 1, iz usporedbe *Slike 5.12. (c)* sa *Slikom 5.13. (c)* očito je da *Skup 8* ima manju količinu podataka koji su izvan pravca koji sa horizontalnom osi zatvara kut od  $45^\circ$ . A to se vidi i na ostalim grupama podataka, tj. podacima za trening (*a*), podacima za validaciju (*b*) i ukupnim podacima (*d*). Isto vrijedi i za regresije za ostale skupine podataka. Podudarnost podataka sa spomenutim pravcem odražava uspješnost pojedinog koraka treniranja UNM-e.



Slika 5.12 Regresija za Skup 1 – NARX

(a) za skup trening podataka, (b) za skup validacijskih podataka, (c) za skup testnih podataka,  
 (d) za ukupni skup podataka



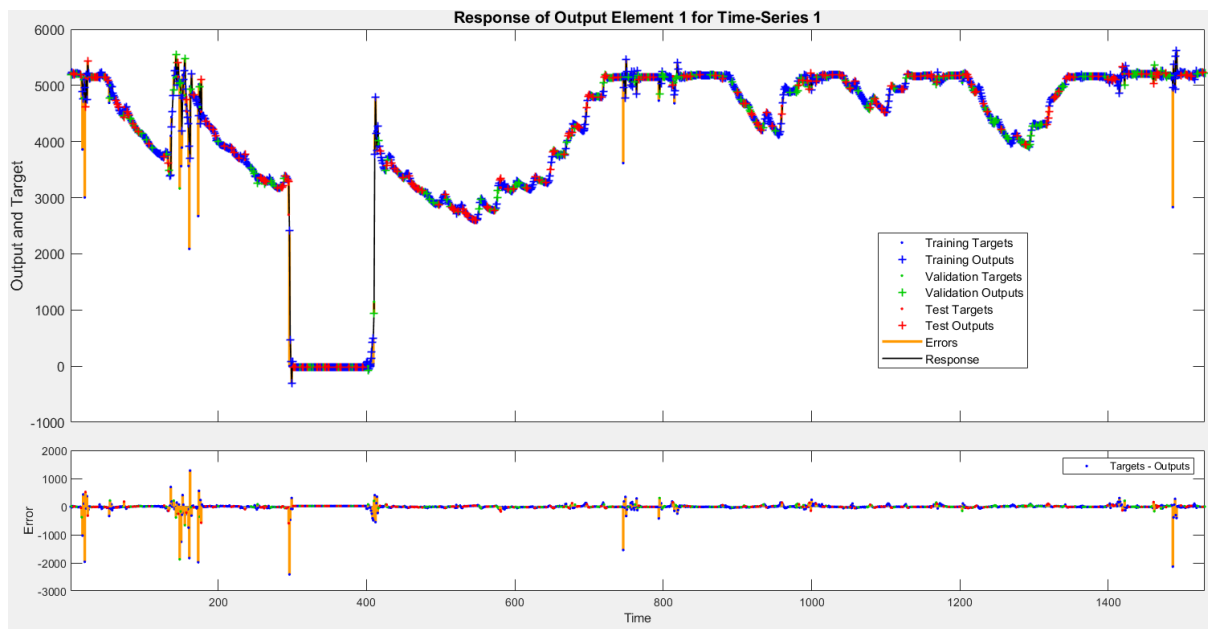


Slika 5.13. Regresija Skup 8 – NARX


(a) za skup trening podataka, (b) za skup validacijskih podataka, (c) za skup testnih podataka, (d) za ukupni skup podataka

Na Slikama 5.14. , 5.15., 5.16. i 5.17. su na gornjem dijelu grafički prikazani odzivi za model Skupa 1 i model Skupa 8. Na vertikalnoj osi su označene “target” vrijednosti, a na horizontalnoj vremenski uzorci. Broj uzoraka odgovara broju podataka u skupu, koji se mogu vidjeti u Tablici 5.1. . Krugovima su označene “target” vrijednosti trening, validacijskih i testnih podataka. Plusevima su označene izlazne vrijednosti trening, validacijskih i testnih podataka. Narančastom bojom na donjem dijelu su prikazane samo pogreške. Kao što se vidi, oba modela su u stanju jako dobro predvidjeti veliku većinu “target” vrijednosti snaga uz povremene

intenzivne greške. Očito je da se kod modela za *Skup 8* rjeđe javljaju intenzivne pogreške. Na *Slikama 5.16. i 5.17.* su prikazani uvećani segmenti jednoga i drugog odziva, na slikama se vidi da za skoro svaki uzorak postoji barem malo odstupanje izlazne vrijednosti od “*target*” vrijednosti.




*Slika 5.14. Odziv za Skup 1 - NARX*




*Slika 5.15. Odziv za Skup 8 - NARX*

Na *Slici 5.14 i Slici 5.15.* horizontalne, tj. vremenske osi gornjeg i donjeg dijela slike se podudaraju. Što znači da su narančaste crte koje označavaju pogrešku istovjetne i za gornji i donji dio *Slike 5.14. i Slike 5.15.*

Na *Slici 5.16* i *Slici 5.17* to nije slučaj. Horizontalne osi se ne podudaraju i narančaste crte za pogrešku nisu istovjetne. Smisao ove dvije slike je uvećani prikaz odziva za pojedini model i uvećani prikaz reda veličine pogrešaka na područjima odziva gdje model najbolje predviđa “target” vrijednosti.



*Slika 5.16. Uvećani odziv Skupa 1 - NARX*



*Slika 5.17. Uvećani odziv Skupa 8 – NARX*

## 5.5. Rezultati NAR strukture za LM algoritam

NAR struktura kao ulaz ima samo parametar „*target*“ snaga iz onih skupova koji su formirani za NARX strukturu. S obzirom da kod ove strukture *Skup 1* i *Skup 2* postaju isti skup, u nastavku će se pisati samo „*Skup 1*“, a „*Skup 2*“ će biti izostavljen kako bi se održala istovjetnost označavanja skupova i tablica zbog lakše usporedbe NARX i NAR strukture.

NAR struktura je također testirana za 10, 50, 100 i 500 neurona, s rasponom „*delay-a*“ od 1 do 5. Vrijednost Pearsonovog koeficijena R je najčešće približno 1, što govori da postoji jaka veza između ulaznih i izlaznih podataka. Za veće RMSE vrijenosti primjećuje se pad korelacije. Primjer rezultata podataka je pokazan u *Tablici 5.9.*, u tablici se nalaze rezultati za *Skup 1*. Najmanja RMSE vrijednost u skupu je podebljana.

*Tablica 5.9. RMSE vrijednosti za Skup 1 - NAR*


Broj neurona	Broj „ <i>delay-a</i> “	RMSE	R
10	1	117.53	1.00
	2	120.00	1.00
	3	127.43	1.00
	4	101.76	1.00
	5	102.82	1.00
50	1	148.18	0.99
	2	<b>50.55</b>	1.00
	3	166.03	0.99
	4	180.20	0.99
	5	205.38	0.99
100	1	233.41	0.99
	2	103.74	1.00
	3	192.18	0.99
	4	308.54	0.97
	5	200.53	0.99
500	1	265.70	0.98
	2	390.76	0.96
	3	605.04	0.92
	4	526.78	0.94
	5	367.15	0.97

Na *Slici 5.18.* prikazane su ovisnosti RMSE o broju „*delay-a*“ za *Skup 1*. A na *Slici 5.19.* su prikazane ovisnost RMSE o broju neurona za svaki od „*delay-a*“ za *Skup 1*.

Kod ovisnosti o RMSE vrijednosti o broju „*delay-a*“ za *Skup 1*, u tri navrata linearna regresija ima pozitivan koeficijent a negativan u jednom. Za broj neurona iznosa 10, koeficijent je negativan, za broj neurona iznosa 50, 100 i 500 koeficijent regresije je pozitivan. Općenito, ako promatramo sve skupove, uzlazne regresije se u 81.25% slučajeva, tj. u 13 od 16 slučajeva pojavljuju za broj neurona iznosa 50 i 100. Dok se silazne regresije u 91.67% slučajeva, tj. u 11 od 12 slučajeva, pojavljuju za broj neurona iznosa 10 i 500. Za razliku od NARX strukture, kod NAR strukture se nazire čvršći logički obrazac ponašanja RMSE u ovisnosti o broju „*delay-a*“. Za Vrijednosti neurona 50 i 100 performanse sustava padaju, dok za vrijednosti neurona 10 i 500 povećanjem „*delay-a*“ performanse sustava rastu. Navedeno se može vidjeti u *Tablici 5.10.* .

*Tablica 5.10. Raspored pojavnosti regresija za ovisnost RMSE vrijednosti o broju „delay-a“ - NAR*

Redni broj skupa	Broj uzlaznih regresija	Broj neurona za uzlazne regresije	Broj silaznih regresija	Broj neurona za silazne regresije
1 i 2	3	50, 100, 500	1	10
3	3	50, 100, 500	1	10
4	2	50,100	2	10, 500
5	2	50, 100	2	10, 500
6	3	10, 50, 100	1	500
7	2	50, 100	2	10, 500
8	1	50	3	10, 100, 500
<b>Ukupno:</b>	<b>16</b>	<b>1x10, 7x50, 6x100, 2x500</b>	<b>12</b>	<b>6x10, 0x50, 1x100, 5x500</b>



Slika 5.18. Ovisnost RMSE o broju „delay-a“ za svaki od broja treniranih neurona - NAR

Kod ovisnosti RMSE o broju neurona za *Skupu 1* u NAR strukturi, u svih pet slučajeva regresija je uzlazna, kao i kod NARX strukture. I ne samo u *Skupu 1*, nego u svim ostalim skupovima je svaka regresija (35 njih!) izrazito uzlazna, na osnovu čega se može zaključiti da povećanjem broja neurona RMSE raste, tj. povećanje broja neurona loše utječe na performanse sustava, uz svojevrsnu anomaliju, u odnosu na NARX strukturu, što se većina najmanjih pogrešaka javlja za broj neurona iznosa 50, što je mana u odnosu na NARX strukturu jer više neurona podrazumijeva rast kompleksnosti mreže.


To se može zaključiti analiziranjem pozicije na kojoj se u svakom pojedinom skupu javlja najmanja pogreška, tj. *Tablice 5.11*.

*Tablica 5.11. Najmanje RMSE vrijednosti za svaki od skupova - NAR*

Redni broj skupa	Broj neruona za najmanji RMSE	Broj „delay-a“ za najmanji RMSE	Vrijednost najmanje RMSE
1 i 2	50	2	50.55
3	10	5	51.61
4	10	4	66.92
5	50	2	34.07
6	50	1	48.23
7	50	2	15.63
8	50	4	<b>14.38</b>

Kao što je iz *Tablice 5.11.* vidljivo, u 5 od 7 slučajeva najmanja pogreška se javila na mreži od 50 neurona. Za razliku od NARX strukture, u NAR strukturi se ne vide implikacije o najboljem izboru vrijednosti „delay-a“. Razlika između najmanje i najveće RMSE vrijednosti je manja nego kod NARX strukture, što se može objasniti time što NAR struktura na ulazu ima samo „target“ podatke, pa su sami skupovi međusobno puno sličniji. Unatoč povećanoj sličnosti skupova ulaznih podataka, primjećuje se da su rezultati manje kompleksnih skupova podataka bolji.

U *Tablici 5.12.* su prikazani detaljniji rezultati za svaki od skupova te su uspoređeni sa *Tablicom 5.5.* .



Slika 5.19. Ovisnost RMSE o broju neurona za svaki od „delay-a“ - NAR



Tablica 5.12. Detaljnija tablica RMSE vrijednosti po skupovima - NAR

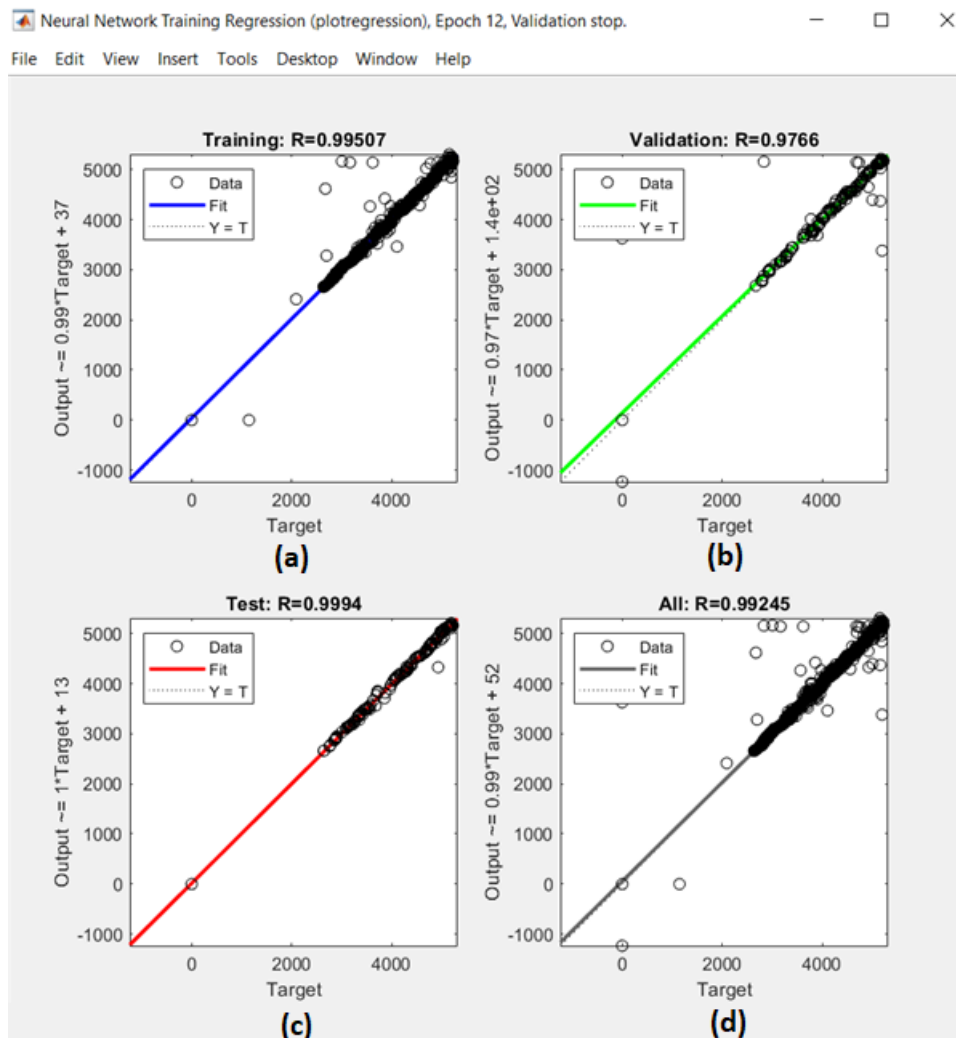
Redni broj skupa	Broj neurona	Prosjek RMSE za svih pet „delay-a“	Redni broj skupa	Broj neurona	Prosjek RMSE za svih pet „delay-a“
1	10	113.91			
	50	150.07			
	100	207.68			
	500	431.09			
	Prosjek svih RMSE iz skupa	225.69			
3	10	172.79	4	10	100.99
	50	147.93		50	123.96
	100	186.52		100	153.76
	500	450.20		500	480.48
	Prosjek svih RMSE iz skupa	239.36		Prosjek svih RMSE iz skupa	214.80
5	10	78.54	6	10	83.12
	50	119.25		50	133.24
	100	145.45		100	161.33
	500	438.98		500	464.17
	Prosjek svih RMSE iz skupa	195.55		Prosjek svih RMSE iz skupa	210.47
7	10	23.15	8	10	22.18
	50	35.87		50	29.26
	100	37.50		100	36.91
	500	183.87		500	156.32
	Prosjek svih RMSE iz skupa	70.10		Prosjek svih RMSE iz skupa	<b><u>61.17</u></b>

Najmanji prosjek svih RMSE vrijednosti u skupu je u *Skupu 8* i iznosi 61.17, prosjeci za skupove koji imaju kompleksnije podatke su znatno veći, kao i kod NARX strukture. Uspoređivanjem s vrijednostima za NARX strukturu, Tj. uspoređivanjem *Tablice 5.12.* i *Tablice 5.5.*, vidi se da su prosjeci svih RMSE vrijednosti za *Skupove* u 6 navrata bolji za NAR strukturu što navodi na zaključak da je NAR struktura bolja od NARX strukture.

U nastavku će biti grafički prikazan odziv za *Skup 8* koji ima najmanju vrijednost RMSE iznosa 14.38, i odziv za skup koji obrađuje najkompleksnije podatke, to je *Skup 1* kojemu je RMSE vrijednost iznosa 50.55.

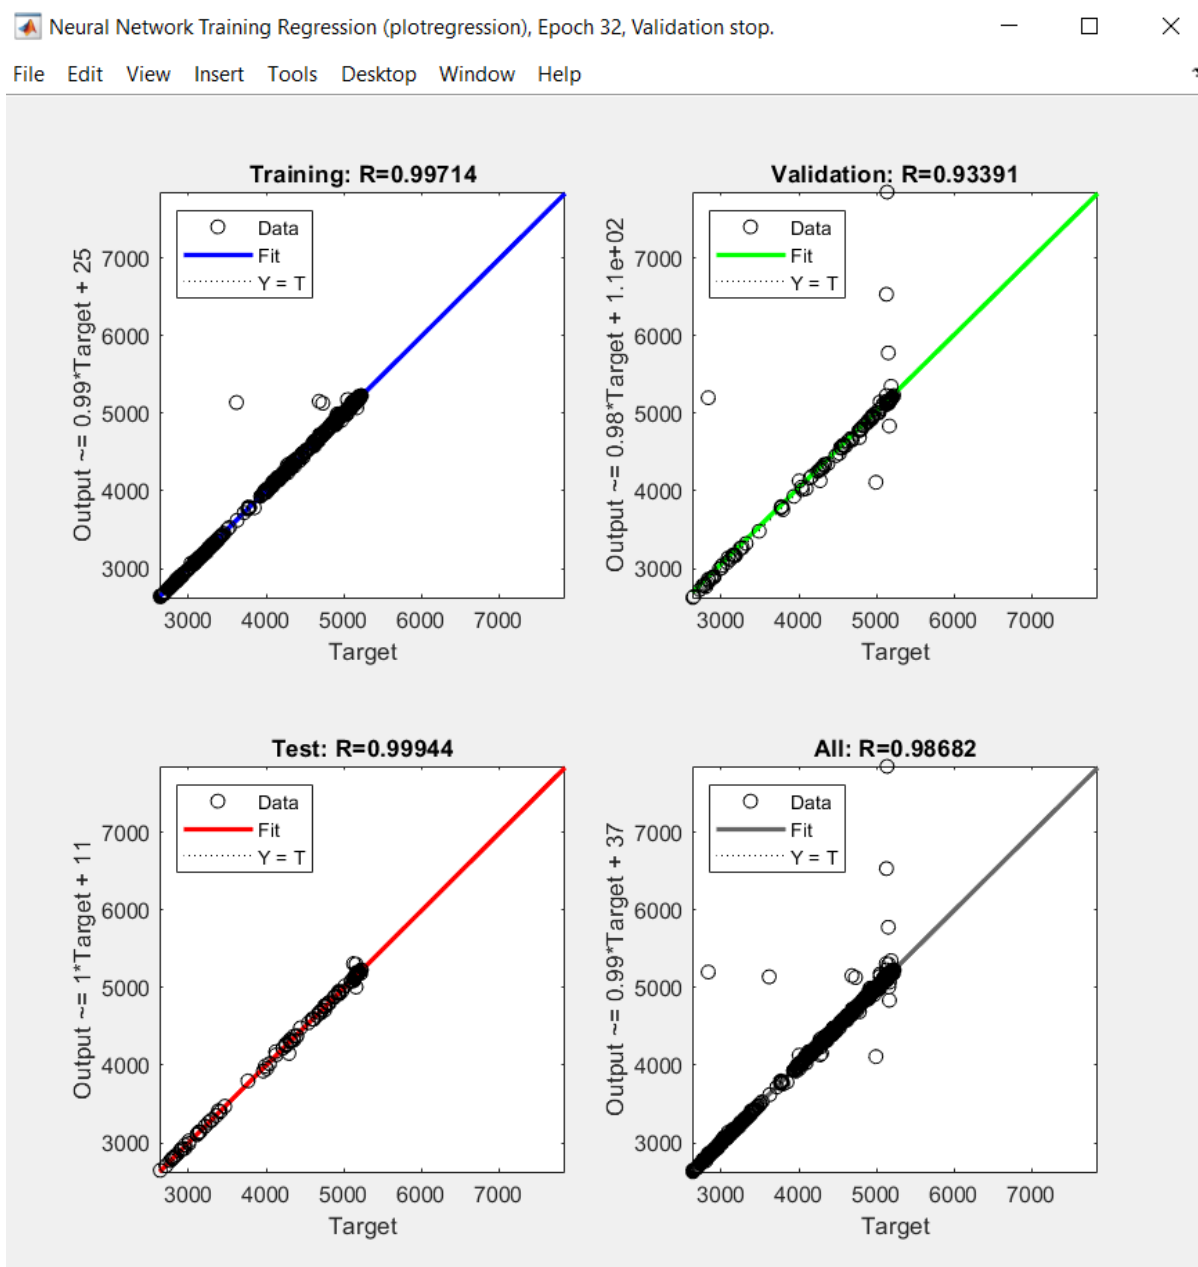
Proveden je novi test za *Skup 1*, nakon 10 “retrain-a” vrijednost najmanjeg RMSE je iznosila 50.53. Pearsonov koeficijent R je iznosio 0.99. Također je proveden novi test za *Skup 8*, nakon 10 “retrain-a” vrijednost najmanjeg RMSE je iznosila 28.38 što je dvostruko više nego u prvom testiranju, ali i dalje najmanje od RMSE vrijednosti ostalih skupova. Pearsonov koeficijent R je iznosio 0.99. Najzanimljiviji skupovi na kraju su ponovno “retrain-ani” kako bi se zabilježile njihove grafičke karakteristike, bilježenje grafičkih karakteristika svih testova bi bilo previše vremeniski zahtjevno.

*Slika 5.20.*, i *Slika 5.21.* grafički prikazuju regresije za rezultate *Skupa 1* i *Skupa 8*. Kao i za NARX strukturu, iako su vrijednosti Pearsonovog koeficijenta R za testu skupinu podataka za oba primjera približno 1, sa slika je očito da *Skup 8* ima manju količinu testnih podataka koji su izvan crvene crte (*c*). Isto vrijedi i za regresije trening (*a*), validacijske (*b*) i ukupne skupine podataka (*d*).



Slika 5.20. Regresija za Skup 1 – NAR

(a) za skup trening podataka, (b) za skup validacijskih podataka, (c) za skup testnih podataka,  
(d) za ukupni skup podataka




Slika 5.21. Regresija za Skup 8 – NAR


(a) za skup trening podataka, (b) za skup validacijskih podataka, (c) za skup testnih podataka, (d) za ukupni skup podataka

Na Slikama 5.23. , 5.24. , 5.25. i 5.26. su na gornjem dijelu grafički prikazani odzivi za Skup 1 i Skup 8. Na vertikalnoj osi su označene “target” vrijednosti, na horizontalnoj osi su vremenski uzorci. Broj uzoraka odgovara broju podataka u skupu, koji se mogu vidjeti u Tablici 5.1. . Krugovima su označene “target” vrijednosti trening, validacijskih i testnih podataka. A Plusevima su označene izlazne vrijednosti trening, validacijskih i testnih podataka. Narančastom crtom na donjem dijelu su prikazane samo pogreške.


Kao i u slučaju za NARX strukturu, oba modela su u stanju jako dobro predvidjeti veliku većinu “target” vrijednosti snaga uz povremene intenzivne greške. Očito je da se kod modela za *Skup* 8 rjeđe javljaju intenzivne pogreške. Na *Slikama* 5.22 i 5.23 su prikazani uvećani segmenti jednog i drugog odziva. Na slikama se vidi da za skoro svaki uzorak postoji barem malo odstupanje izlazne vrijednosti od “target” vrijednosti.




*Slika* 5.22. Odziv za *Skup* 1 - NAR



*Slika* 5.23. Odziv za *Skup* 8 - NAR



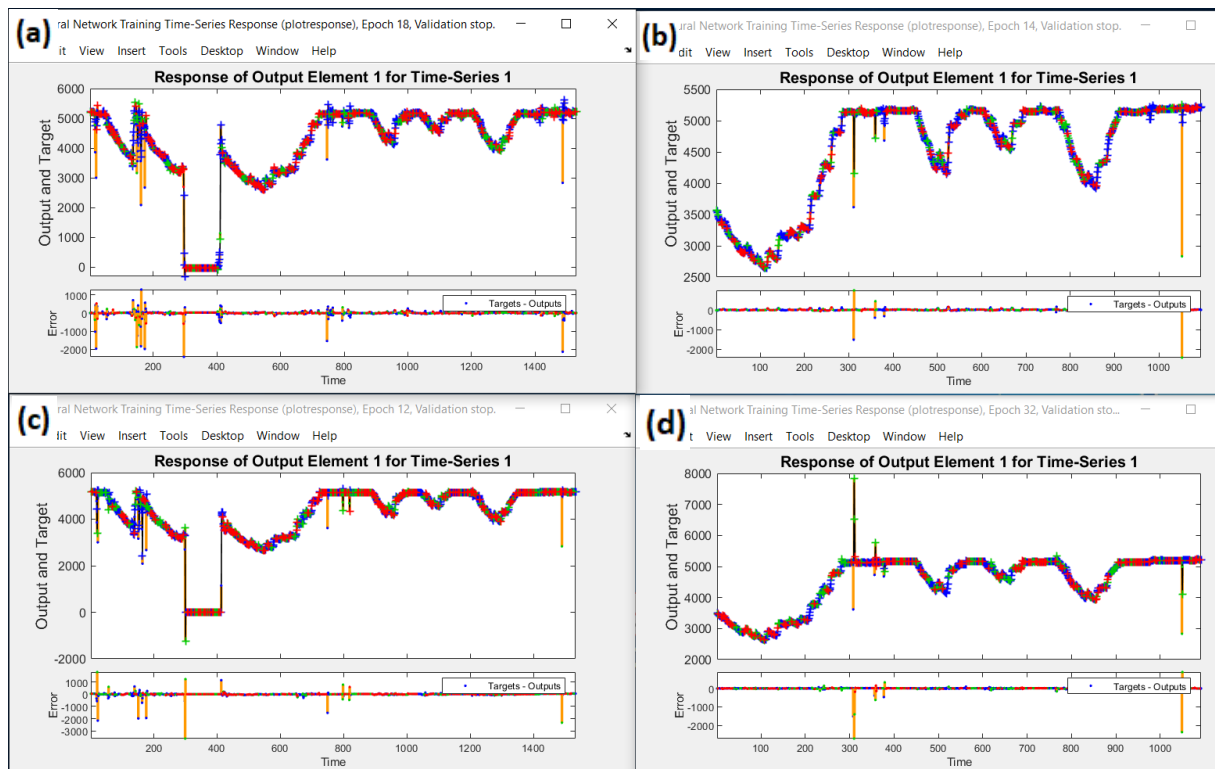
Slika 5.24. Uvećani odziv Skupa 1 - NAR



Slika 5.25. Uvećani odziv Skupa 8 - NAR

Na Slici 5.26. su, radi lakše usporedbe, prikazani odzivi za četiri odabrana skupa podataka, na Slici 5.26. (a) se nalazi odziv za Skup 1 NARX strukture, a na Slici 5.26. (b) odziv za Skup 8 NARX strukture.

Na Slici 5.26. (c) se nalazi odziv za Skup 1 NAR strukture, dok se na Slici 5.26. (d) nalazi odziv za Skup 8 NAR strukture. Sa slika je očito da su odzivi vrlo slični unatoč tome što NAR strukutra općenito daje manje RMSE vrijednosti.



Slika 5.26. Usporedba odziva za NARX i NAR strukturu

(a) odziv za Skup 1 NARX strukture, (b) odziv za Skup 8 NARX strukture, (c) odziv za Skup 1 NAR strukture, (d) odziv za Skup 8 NAR strukture

U Tablici 5.13. nalaze se općenite karakteristike NARX i NAR strukture vezane za rezultate testova u ovome radu.

Tablica 5.13. Općenite karakteristike NARX i NAR strukture

NARX	NAR
Najmanji RMSE svih skupova je veći nego za NAR strukturu.	Najmanji RMSE svih skupova je manji nego za NARX strukturu.
Najveći RMSE svih skupova je veći nego za NAR strukturu.	Najveći RMSE svih skupova je manji nego za NARX strukturu.
Slabiji logički obrazac ponašanja RMSE u ovisnosti o broju „ <i>delay-a</i> “ u odnosu na NAR.	Čvršći logički obrazac ponašanja RMSE u ovisnosti o broju „ <i>delay-a</i> “ u odnosu na NARX.
Najbolje RMSE vrijednosti po skupovima se najčešće javljaju za mrežu od 10 neurona.	Najbolje RMSE vrijednosti po skupovima se najčešće javljaju za mrežu od 50 neurona.
Postoji implikacija da je vrijednost „ <i>delay-a</i> “ iznosa 1 najbolji izbor.	Ne postoji neka implikacija.
Kod ovisnosti RMSE o broju neurona, sve regresije su uzlazne, manje neurona - bolja mreža.	Kod ovisnosti RMSE o broju neurona, sve regresije su uzlazne, manje neurona - bolja mreža.



## 6. ZAKLJUČAK

Nakon obavljenih testova i njihove analize može se zaključiti da se UNM-e mogu upotrijebiti u svrhu unaprijeđivanja procesa proizvodnje električne energije. To se ponajviše vidi iz grafičkih prikaza odziva različitih modela. No, relativnu kvalitetu rezultata je teško ocijeniti unatoč najčešće odličnim vrijednostima Pearsonovog koeficijenta  $R$ , jer zaključak o relativnoj kvaliteti uvelike ovisi o specifičnijim zahtjevima svakog problema zasebno, zbog čega su i razvijene brojne druge relativne mjere kvalitete, od kojih su neke spomenute u *Poglavlju 4.6.* . U svakom slučaju, smisao ovoga rada je bio provjeriti da li uopće postoji potencijal za upotrebu UNM-a u procesu proizvodnje električne energije, ocijeniti koja struktura mreže bi za to bila najprikladnija, ocijeniti utjecaj različitih tipova ulaznih podataka na izlaz. Kao što je navedeno, pokazano je da postoji potencijal za upotrebu UNM-a u proizvodni električne energije, te da je za to najbolja NAR struktura mreže. Na osnovu usporedbe sa NARX strukturom, može se zaključiti da se najbolji rezultati dobivaju kada je na ulazu modela dovedena samo varijabla  $Y_P(t)$  (NAR struktura), drugi rezultati po kvaliteti se dobivaju kada se na ulaz dovedu varijable  $X_{On}(t)$ ,  $Y_T(t)$ ,  $Y_P(t)$  (NARX struktura), najlošiji rezultati se dobivaju kada se na ulaz dovedu varijable  $X_{On}(t)$  i  $Y_{Pn}(t)$ , uz napomenu da se ovi zaključci trebaju uzimati sa mjerom opreza iz razloga navedenih u analizi dobivenih rezultata. Nedvosmisleno se može zaključiti da RMSE vrijednost pada sa padom broja neurona tj. sa padom kompleksnosti UNM-e za obje testirane strukture, uz anomaliju kod NAR strukture gdje se najmanji RMSE najčešće javljao za mrežu od 50 neurona. Kod NARX strukture postoji implikacija da se najbolji rezultati dobivaju za vrijednost „*delay-a*“ iznosa 1, dok takva implikacija ne postoji kod NAR strukture. Kompleksnost podataka utječe na rezultate testova, veća kompleksnost podrazumijeva veću pogrešku.

Osim na početku analize spomenutog problema u prekidima bilježenja podataka, problem je također njihova količina. Autoregresivni algoritmi uče na temelju kvaziperiodičnosti funkcija koje obrađuju, u slučaju klimatologije, kvaziperiodičnosti vremenskih prognoza, uključujući i prognoze o oborinama, se pojavljuju kvaziperiodički u ovisnosti o godišnjim dobima, Sunčevim ciklusima, nagibu osi rotacije Zemlje... Da bi algoritam iskoristio ovu pojavu u procesu učenja, potrebno bi bilo prikupljati podatke tijekom višegodišnjeg vremenskog razdoblja. U [38] se nalazi rad koji proveden upravo na taj način.

# LITERATURA

- [1] Wikipedia: “Hidroelektrana”, s Interneta, <https://hr.wikipedia.org/wiki/Hidroelektrana>, 6. Kolovoza 2019.
- [2] Hrvatska Elektroprivreda: “Hidroelektrane”, s Interneta, <http://www.hep.hr/proizvodnja/hidroelektrane-1528/1528>, 6. Kolovoza 2019.
- [3] Woodbank Communications Ltd 2005: “Energy Efficiency”, s Interneta, [https://www.mpoweruk.com/energy\\_efficiency.htm](https://www.mpoweruk.com/energy_efficiency.htm), 6. Kolovoza 2019.
- [4] Elsevier B.V. or its licensors or contributors, ScienceDirect ®: “Hydropower Plant”, s Interneta, <https://www.sciencedirect.com/topics/engineering/hydropower-plant>, 6. Kolovoza 2019.
- [5] Dozvola za rad za proizvodnju električne energije, Amitea-ii“ d.o.o. mostar, s Interneta, [http://www.ferk.ba/\\_ba/images/stories/2016/dozvola\\_amitea\\_II\\_bs.pdf](http://www.ferk.ba/_ba/images/stories/2016/dozvola_amitea_II_bs.pdf), 6. Kolovoza 2019.
- [6] European Small Hydropower Association – ESHA, “Guide on How to Develop a Small Hydropower Plant”, s Interneta, [https://energiatalgud.ee/img\\_auth.php/a/ab/Guide\\_on\\_How\\_to\\_Develop\\_a\\_Small\\_Hydropower\\_Plant.pdf](https://energiatalgud.ee/img_auth.php/a/ab/Guide_on_How_to_Develop_a_Small_Hydropower_Plant.pdf), 6. Kolovoza 2019.
- [7] Asodi M.: “Tehno-Ekonomska analiza male hidroelektrane”, s Interneta, [http://repozitorij.fsb.hr/1445/1/11\\_07\\_2011\\_zavrsni\\_rad\\_m\\_asodi.pdf](http://repozitorij.fsb.hr/1445/1/11_07_2011_zavrsni_rad_m_asodi.pdf), 8. Kolovoza 2019.
- [8] Ćipranić I.: “Vodozahvat u dnu (Tirolski vodozahvat)”, s Interneta, [https://www.researchgate.net/publication/267179549\\_Vodozahvat\\_u\\_dnu\\_Tirolski\\_vodozahvat](https://www.researchgate.net/publication/267179549_Vodozahvat_u_dnu_Tirolski_vodozahvat), 8. Kolovoza 2019.
- [9] Bošnjak M.: “Režimi rada HE Pleternica”, Sveučilište Josipa Jurja Strossmayera u Osijeku, Elektrotehnički Fakultet, Osijek, 2014.
- [10] Mishra P.: “Pelton Turbine Working, Main Parts, Application with Diagram”, s Interneta, <https://www.mechanicalbooster.com/2016/10/pelton-turbine-working-main-parts-application-with-diagram.html>, 9. Kolovoza 2019.
- [11] Wikipedia: “Električni generatori”, s Interneta, [https://hr.wikipedia.org/wiki/Elektri%C4%8Dni\\_generator](https://hr.wikipedia.org/wiki/Elektri%C4%8Dni_generator), 10. Kolovoz 2019.
- [12] Kumar Rana R.: “Selecting Transformers For Hydro Power”, s Interneta, <https://sites.google.com/site/rajeshmechanical86/mechanical-seminar/selecting-transformers-for-hydro-power>, 11. Kolovoza 2019.
- [13] Narodne novine (NN) 36/2006: “Mrežna pravila elektroenergetskog sustava, s Interneta, [https://narodne-novine.nn.hr/clanci/sluzbeni/2006\\_03\\_36\\_907.html](https://narodne-novine.nn.hr/clanci/sluzbeni/2006_03_36_907.html), 11. Kolovoza 2019.

- [14] Hrvatski ogranak međunarodnog vijeća za velike elektroenergetske sustave: “Planiranje pomoćnih usluga”, s interneta, [https://bib.irb.hr/datoteka/369067.Pozvani\\_referat.pdf](https://bib.irb.hr/datoteka/369067.Pozvani_referat.pdf), 14. Rujna 2019.
- [15] Element d.o.o, “Elektroenergetski sustav”, s Interneta, <https://element.hr/artikli/file/2477>, 14. Rujna 2019.
- [16] Trožić-Borovac S., Macanović A., Škrijelj R.: “Morfometrijske karakteristike i kondicioni indeks Austropotamobius pallipes iz sliva rijeke Neretve”, s Interneta, [http://sfsa.unsa.ba/nauka/dokumenti/Radovi-2012-2/2012\\_2\\_2\\_Trozic-Borovac.pdf](http://sfsa.unsa.ba/nauka/dokumenti/Radovi-2012-2/2012_2_2_Trozic-Borovac.pdf), 14. Kolovoz 2019.
- [17] FEDERALNO MINISTARSTVO OKOLIŠA I TURIZMA, Sektor za okolinske dozvole, Sarajevo: “Studija o procjeni uticaja na okoliš za mHE Kraljušćica 1, mHE Kraljušćica 2 i mHE Kraljušćica – mišljenje”, s Interneta, [http://zeleni-neretva.ba/index2.php?option=com\\_docman&task=doc\\_view&gid=3&Itemid=52](http://zeleni-neretva.ba/index2.php?option=com_docman&task=doc_view&gid=3&Itemid=52), 14. Kolovoza 2019.
- [18] JP Elektroprivreda BiH d.d. Sarajevo, “Obrazloženje prijedloga odluke o usvajanju Izvještaja o poslovanju JP Elektroprivreda BiH d.d. – Sarajevo za 2015. godinu”, s Interneta, <https://www.epbih.ba/upload/documents/Tacaka2materijal35.pdf>, 17. Rujna 2019.
- [19] Edureka!: “AI vs Machine Learning vs Deep Learning | Machine Learning Training with Python | Edureka”, s Interneta, <https://www.youtube.com/watch?v=WSbgixdC9g8>, 14. Kolovoza 2019.
- [20] Sveučilište u Zagrebu Fakultet elektrotehnike i računarstva: “Strojno učenje“, s Interneta, <https://www.fer.unizg.hr/predmet/su>, 14. Kolovoza 2019.
- [21] Sveučilište u Zagrebu Fakultet elektrotehnike i računarstva: “Duboko učenje“, s Interneta, <https://www.fer.unizg.hr/predmet/dubuce>, 14. Kolovoza 2019.
- [22] Richard Morris, Marianne Fillenz: "Neuroznanost, znanost o mozgu", Liverpool, UK TheBritish Neuroscience Association 2003. g.
- [23] Perković T.: “Jednostavi analitički model ljudskog živca temeljen na teoriji antena”, Sveučilište u Splitu, Fakultet Elektrotehnike Strojarsstva i Brodogradnje, Split, 2015. g.
- [24] Matić P.: “Kratkoročno predviđanje hidrološkog dotoka pomoću umjetne neuronske mreže”, Sveučilište u Splitu, Fakultet Elektrotehnike Strojarsstva i Brodogradnje, Split, 2014. g.
- [25] Wikipedia: “Linear separability”, s Interneta, [https://en.wikipedia.org/wiki/Linear\\_separability](https://en.wikipedia.org/wiki/Linear_separability), 15. Kolovoza 2019.
- [26] R. Rojas: “Weighted Networks – The Perceptron “, s Interneta, <http://page.mi.fu-berlin.de/rojas/neural/chapter/K3.pdf>, 15. Kolovoza 2019.

- [27] R. Rojas: “ Perceptron Learning “, s Interneta, <http://page.mi.fu-berlin.de/rojas/neural/chapter/K4.pdf> , 15. Kolovoza 2019.
- [28] Humphrys M. School of Computing. Dublin City University : “Single-layer Neural Networks (Perceptrons)”, s Interneta, <https://computing.dcu.ie/~humphrys/Notes/Neural/single.neural.html>, 15. Kolovoza 2019.
- [29] Hanson Robotics Limited: “Sophia the Robot by Hanson Robotics”, s Interneta, <https://www.youtube.com/watch?v=BhU9hOo5Cuc&t>, 16. Kolovoza 2019.
- [30] The University of Wisconsin Madison: “A Basic Introduction To Neural Networks”, s Interneta, 16. Kolovoza 2019.
- [31] Brownlee J.: “Time Series Forecasting as Supervised Learning”, s Interneta, <https://machinelearningmastery.com/time-series-forecasting-supervised-learning/>, 18. Kolovoza 2019.
- [32] Kumar M.: “Artificial neural network, perceptron learning rule...(Part-1)”, s Interneta, <https://www.linkedin.com/pulse/artificial-neural-network-perceptron-learning-rule-mukesh-kumar/?=,> 21. Kolovoza 2019.
- [33] Henri P. Gavin: “The Levenberg-Marquardt algorithm for nonlinear least squares curve-fitting problems”, s Interneta, <http://people.duke.edu/~hpgavin/ce281/lm.pdf>, 12. Rujna 2019.
- [34] Burden F., Winkler D.: “Bayesian Regularization of Neural Networks”, s Interneta, [https://link.springer.com/protocol/10.1007/978-1-60327-101-1\\_3](https://link.springer.com/protocol/10.1007/978-1-60327-101-1_3), 12. Rujna 2019.
- [35] Statistics How To: “Autoregressive Model: Definition & The AR Process”, <https://www.statisticshowto.datasciencecentral.com/autoregressive-model/>, 12. Rujna 2019.
- [36] P. B. Jelušić: “Izrada automatiziranog sustava kalkulacija korištenjem neuronskih mreža”, s Interneta, [https://eprints.grf.unizg.hr/2500/1/DB532\\_Jelu%c5%a1i%c4%87\\_Petar\\_Branislav.pdf](https://eprints.grf.unizg.hr/2500/1/DB532_Jelu%c5%a1i%c4%87_Petar_Branislav.pdf), 14. Rujna 2019.
- [37] N.J. de Vos, T.H.M. Rientjes: “Constraints of artificial neural networks for rainfall-runoff modelling: trade-offs in hydrological state representation and model evaluation”, Water Resources Section, Delft University of Technology, Delft, The Netherlands, 2005.
- [38] A. T. Hammid, M. H. Bin Sulaiman, A. N. Abdalla: “Prediction of small hydropower plant power production in Himreen Lake dam (HLD) using artificial neural network”, s Interneta, <https://www.sciencedirect.com/science/article/pii/S111001681630343X>, 4. Rujan 2019.

# POPIS KRATICA I OZNAKA

## Kratice:

AR - autoregressive  
BiH - Bosna i Hercegovna  
DC - istosmjerna struja (*eng. Direct current*)  
E - pogreška  
EES - elektro energetski sustav  
GRNN - generalized regression neural networks  
HE - Hidroelektrana  
LM Levenberg-Marquardt algoritam za treniranje UNM-a  
MAE –srednja apsolutna pogreška (*eng. mean absolute error*)  
MHE - mala hidroelektrana  
MLP - višeslojni perceptron (*eng. multilayer perceptron*)  
MNM - metara nadmorske visine  
MSE - srednja kvadratna pogreška (*eng. mean squared error*)  
NAND - NILI logička funkcija (*eng. NOT-AND*)  
NAR - nelinearna autoregresivna struktura UNM-e (*eng. nonlinear autoregressive*)  
NARX - nelinearna autoregresivna struktura UNM-e s vanjskim ulazima (*eng. nonlinear autoregressive with exogenous input*)  
ODS - operator distribucijskog sustava  
OPS - operator prijenosnog sustava  
RBF – neuronske mreže s prijenosnom funkcijom radijalne baze (*eng. radial basis function*)  
RBS – Redni brojevi skupova, *Tablica 5.5.*  
RMSE –korijen srednje kvadratne pogreške (*eng. root mean squared error*)  
RNN - recurrent neural networks,  
SOM - samoorganizirajuće mape  
SSE - zbroj kvadratne pogreške (*eng. sum of squared error*)

**Oznake:**

$b$  – “*bias*” vrijednost umjetnog neurona

$CE$  - koeficijent učinkovitosti

$d$  – “*delay*” ; broj članova vremenske serije

$h_1, h_2$  - neuroni u mreži

$o_k$  - izlaz umjetnog neurona

$p_k$  - ukupna (otežana) vrijednost ulaznog signala umjetnog neurona

$P_n$  – točka u dvodimenzionalnom prostoru koja označava kombinaciju ulaznih podatak  $X_1, X_2$

$R$  - Pearsonov koeficijent

$r^2$ - koeficijent neodređenosti

$t$  - vrijeme

$u_k$  - ulazi umjetnog neurona

$w$  - podesivi parametri UNM-e, težinski koeficijenti međuneuronskih veza

$x$  – oznaka za “puta” u *Tablici 5.3.* i *Tablici 5.10*

$X_1, X_2$  – ulazi u neuronsku mrežu za primjer sa logičkim funkcijama

$X_{On}(t)$  – Podatci o prognozama oborina za skup pod rednim brojem  $n$ , gdje „O“ označava „oborine“

$X_O(t)$  - Podatci o vremenskim prognozama, gdje „O“ označava „oborine“

$X_O(t)$  – prognozirane oborine

$y$  – izlaz iz neuronske mreže za primjer sa logičkim funkcijama

$Y_P(t)$  -Podatci o snazi iz prošlosti, gdje „P“ označava „prošlost“

$Y_{Pn}(t)$  – Podatci o snagama iz prošlosti za skup pod rednim brojem  $n$ , gdje „P“ označava „prošlost“

$Y_T(t)$  - Trenutni podatci o snazi, gdje „T“ označava „trenutno“.

$Y_{Tn}(t)$  – Podatci o trenutnim snagama za skup pod rednim brojem  $n$ , gdje „T“ označava „trenutno“.

$\phi$  - aktivacijska funkcija umjetnog neurona

## SAŽETAK I KLJUČNE RIJEČI

Tema ovog rada jest ispitivanje korisnosti umjetnih neuronskih mreža u procesu proizvodnje električne energije na temelju podataka o srednjoj izlaznoj snazi male hidroelektrane Kraljušćica 1 i Kraljušćica 2 (Konjic, Bosna i Hercegovina) te vremenskih prognoza za oborine u razdoblju od 5. veljače 2019. u 12:00 sati do 11. travnja 2019. godine u 10:00 sati. Odnosno, na temelju spomenutih podataka je predviđana srednja izlazna snaga male hidroelektrane za 24 sata u budućnost. U drugom poglavlju su dane su osnovne karakteristike malih hidroelektrana i osnovne karakteristike male HE-e Kraljušćica 1 i male HE-e Kraljušćica 2. U trećem poglavlju ovoga rada opisani su temeljni pojmovi iz područja umjetne inteligencije te je općenito opisan način funkcioniranja umjetnih neuronskih mreža. U četvrtom poglavlju su opisani hidrološki sustavi i način primjene umjetnih neuronskih mreža u hidrološkim sustavima. U petom poglavlju su prikazani rezultati testova modela vremenske serije uz dvije korištene strukture umjetne neuronske mreže – NARX i NAR, te Levenberg-Marquardt algoritam za treniranje umjetnih neuronskih mreža. Kratko je analiziran i Bayesian algoritam. Analizom je utvrđeno da NAR struktura polučuje bolje rezultate te da postoji potencijal za korištenje umjetnih neuronskih mreža u procesu proizvodnje električne energije. Testovi su obavljeni uz pomoć MATLAB-ovog alata za testiranje umjetnih neuronskih mreža.

**Ključne riječi:** hidrološki dotok, umjetna neuronska mreža, prognoza oborina, vremenska serija

## ABSTRACT AND KEYWORDS

Topic of this paper is examination of utility of artificial neural networks in the process of producing electricity on the basis of data of the average output power in small hydropower plant Kraljušica 1 and Kraljuščica 2 (Konjic, Bosnia and Herzegovina) and weather forecast for rainfall in the period from February 5th at 12 pm to April 11th at 10 am in 2019. On the basis of this data the output power of this small hydropower plant is predicted 24 hours ahead. In second chapter primary characteristics of small hydropower plants and primary characteristics of small hydropower plants Kraljušica 1 and Kraljušica 2 are explained. In third chapter of this paper basic concepts of the artificial intelligence are described, and the way of artificial neuron networks functioning is described aswell. In fourth chapter hydrological systems are described and the method of usage of artificial neural networks in hydrological systems. In fifth chapter the results of tests of time series models with two used structures of artificial neural network, NARX and NAR and Levenberg-Marquardt algorithm for training of artificial neural networks are shown. Bayesian algorithm is briefly analyzed aswell. The analysis determined that the NAR structure produces better results and that there is potential in using artificial neural networks in the process of producing electricity. These tests were done by MATLAB's tools for testing artificial neural networks.

**Keywords:** hydrological inflow, artificial neural network, rainfall forecast, time series